

Microlectura: 1.1 Qué es Big Data y para qué sirve

1. Contexto histórico

La historia del Big Data no comienza con Google o Amazon. En los años 1960, laboratorios de defensa y ciencia gestionaban los primeros sistemas de datos masivos. En 1990, investigadores de NASA acuñaron el término al enfrentarse a conjuntos de datos de visualización científica que desbordaban la RAM disponible.

Año	Hito	Impacto
1960s	Bases de datos para defensa y ciencia	Primeros sistemas de almacenamiento masivo
1990	NASA acuña "Big Data"	El término entra al vocabulario técnico
2004	Google publica MapReduce	Procesamiento distribuido escalable
2006	Apache Hadoop	Democratización open-source
2011	Apache Spark	Procesamiento en memoria, 100x más rápido
2015-2020	Cloud Computing: AWS, Azure, GCP	Big Data accesible para empresas medianas
2023+	GenAI + Big Data	Los datos masivos alimentan modelos GPT y similares

2. El cambio de paradigma: del muestreo al análisis integral

La estadística clásica resuelve un problema práctico: no podemos medir a toda la población, entonces tomamos una muestra representativa e inferimos. Big Data disuelve esa restricción.

"Más datos superan a algoritmos más inteligentes." — Peter Norvig, Google

Caso concreto: Un banco con 50M de transacciones diarias puede entrenar un modelo de fraude con la totalidad de sus datos históricos, no con el 1% que cabría en memoria RAM convencional. El resultado: reducción de falsos positivos del 40% y ahorro de USD 200M anuales.

3. Las 5V en profundidad

3.1 Volumen

Las métricas globales de 2025 ilustran la escala:

- 181 Zettabytes generados anualmente a nivel mundial (IDC, 2025)
- YouTube: 720.000 horas de video subidas cada día
- CERN LHC: 15 petabytes/segundo durante experimentos
- Meta: 4 petabytes nuevos cada día

3.2 Velocidad

Tres niveles de procesamiento según latencia requerida:

1. **Batch:** Horas/días. Ej: reportes mensuales de ventas.
2. **Micro-batch:** Segundos/minutos. Ej: alertas de inventario.
3. **Streaming:** Milisegundos. Ej: detección de fraude, trading algorítmico.

3.3 Variedad

Distribución típica de tipos de datos en organizaciones modernas:

- Estructurados: 20% (SQL, CSV, Excel)
- Semi-estructurados: 30% (JSON, XML, logs)

- No estructurados: 50% (texto, imágenes, audio, video)

3.4 Veracidad

Métricas clave de calidad de datos:

- Completitud: <20% valores faltantes en datasets curados
- Precisión: >95% en datos validados
- Consistencia: 0 inconsistencias de formato entre sistemas

3.5 Valor

El ROI de Big Data según McKinsey (2024):

- Reducción de costos operativos: 20-30%
- Incremento de ingresos: 15-25%
- Mejora en eficiencia: data-driven decisions reemplazan intuición

4. ¿Qué NO es Big Data?

No toda base de datos grande es Big Data. Una planilla Excel con 100.000 filas no requiere infraestructura distribuida. Big Data implica que las herramientas convencionales son insuficientes. La regla práctica: si R o Python en una sola máquina pueden procesarlo en menos de 10 minutos, probablemente no es Big Data.

5. Caso de estudio: Netflix

Netflix procesa más de 1.000 millones de eventos de usuario diarios para alimentar su sistema de recomendación. Cada perfil tiene más de 5.000 features. El ahorro estimado en retención de clientes supera USD 1.500M anuales. Sin Big Data, cada recomendación sería un costo, no una inversión.