

Analítica de Big Data | FACEN - Universidad Nacional de Asunción | 2026

Subnivel: 1.1 Qué es Big Data y para qué sirve

Práctica Guiada: 1.1 Qué es Big Data y para qué sirve

Dataset: Usaremos datos simulados del sector salud paraguayo (puede descargarse desde el aula o generarse con el código de Ficha 0).

Ficha 0: Preparación del dataset

```
# R - Generar dataset simulado de historiales médicos
set.seed(2026)
n <- 100000 # 100K registros simulados

historiales <- data.frame(
  id_paciente    = 1:n,
  edad           = sample(0:90, n, replace = TRUE),
  sexo           = sample(c("M","F"), n, replace = TRUE),
  diagnostico    = sample(c("Diabetes","Hipertension","Anemia","Otro"), n,
                          replace = TRUE, prob = c(0.25,0.3,0.2,0.25)),
  tiempo_espera  = round(rnorm(n, mean=45, sd=20)),
  region         = sample(c("Central","Alto_Paraguay","Caaguazu","Itapua"), n,
                          replace = TRUE),
  resultado      = sample(c("Alta","Seguimiento","Referido"), n, replace = TRUE)
)

write.csv(historiales, "historiales_salud.csv", row.names = FALSE)
```

```
cat("Dataset generado:", nrow(historiales), "registros")
```

Criterio de completado: El archivo `historiales_salud.csv` existe y tiene exactamente 100.000 filas.

Ficha 1: ¿Es Big Data?

Consigna: Evaluá si el dataset generado es Big Data.

```
library(data.table)
dt <- fread("historiales_salud.csv")

# Diagnóstico de escala
cat("Filas:", nrow(dt), "
")
cat("Columnas:", ncol(dt), "
")
cat("Tamaño en RAM:", format(object.size(dt), units="MB"), "
")
cat("Tipos de variable:", paste(sapply(dt, class), collapse=", "), "
")
```

Pregunta de reflexión: Con 100.000 registros, ¿este dataset es Big Data? ¿Qué debería cambiar para que lo sea? ¿Qué escala usaría un ministerio de salud real?

Criterio de completado: Respondiste la pregunta de reflexión con al menos 2 argumentos concretos que mencionan las 5V.

Ficha 2: Mapeando las 5V

Consigna: Completá la siguiente tabla para el dataset generado Y para un sistema real del Ministerio de Salud Pública del Paraguay.

```
# Código para extraer métricas relevantes
summary_5v <- list(
  Volumen    = paste(nrow(dt), "registros,", format(object.size(dt), units="MB")
  Velocidad  = "Batch diario (no en tiempo real en este caso)",
  Variedad   = paste(ncol(dt), "variables de tipos:", paste(unique(sapply(dt, cl
  Veracidad  = paste("NAs:", sum(is.na(dt)), "de", nrow(dt)*ncol(dt), "valores")
  Valor      = "Identificar regiones con mayor prevalencia de diagnósticos críti
)
print(summary_5v)
```

Criterio de completado: Tabla 5V completada con valores concretos, no solo definiciones abstractas.