

Analítica de Big Data | FACEN - Universidad Nacional de Asunción | 2026

Subnivel: 1.2 Entorno de trabajo: R/RStudio, archivos y lectura de datos

Guía de Funciones: 1.2 Entorno y Lectura de Datos

R — Lectura de distintos formatos

```
# ===== Instalar paquetes (solo una vez) =====
install.packages(c("data.table", "arrow", "readxl", "jsonlite"))

# ===== CSV con data.table (recomendado para Big Data) =====
library(data.table)
dt_csv <- fread("data/raw/datos.csv")
# fread detecta automáticamente: separador, tipos de columna, encoding
# Para archivos con separador diferente:
dt_csv2 <- fread("datos_punto_coma.csv", sep = ";")
# Para seleccionar solo algunas columnas:
dt_selecto <- fread("datos.csv", select = c("id", "edad", "diagnostico"))

# ===== Excel =====
library(readxl)
df_excel <- read_excel("data/raw/informe.xlsx",
                      sheet = "Hojal",    # nombre o número de hoja
                      skip = 2)           # saltar filas de encabezado extra

# ===== JSON =====
library(jsonlite)
lista_json <- fromJSON("datos.json")      # retorna lista o data.frame
df_json <- as.data.frame(fromJSON("datos.json"))
```

```
# ===== Parquet (formato Big Data) =====
library(arrow)
df_parquet <- read_parquet("data/raw/datos.parquet")
# Para datasets grandes, usar Arrow lazy:
ds <- open_dataset("carpeta_con_parquets/")
resultado <- ds |>
  filter(edad > 18) |>
  select(id, edad, diagnostico) |>
  collect() # solo aquí se ejecuta la lectura

# ===== Diagnóstico inicial universal =====
diagnostico <- function(df) {
  cat("=== DIAGNÓSTICO DEL DATASET ===")
  cat("\n")
  cat("Filas:", nrow(df), "| Columnas:", ncol(df), "\n")
  cat("\n")
  cat("Tamaño en RAM:", format(object.size(df), units = "MB"), "\n")
  cat("\n")
  cat("Tipos de variable:\n")
  cat("\n")
  print(sapply(df, class))
  cat("\n")
  cat("Valores faltantes por columna:\n")
  cat("\n")
  print(colSums(is.na(df)))
}
diagnostico(dt_csv)
```

Python — Polars para lectura eficiente

```
import polars as pl
import pandas as pd

# ===== CSV con Polars =====
```

```

df = pl.read_csv("data/raw/datos.csv")
# Con separador diferente:
df2 = pl.read_csv("datos.csv", separator=";")
# Seleccionar columnas específicas:
df3 = pl.read_csv("datos.csv", columns=["id", "edad", "diagnostico"])

# ===== Excel (via pandas) =====
df_excel = pd.read_excel("informe.xlsx", sheet_name="Hoja1", skiprows=2)
df_excel_pl = pl.from_pandas(df_excel) # convertir a Polars si es necesario

# ===== JSON =====
df_json = pl.read_json("datos.json")
# Para JSON por líneas (ndjson):
df_ndjson = pl.read_ndjson("datos_lines.json")

# ===== Parquet =====
df_parquet = pl.read_parquet("datos.parquet")
# Lazy (para archivos muy grandes):
lazy = pl.scan_parquet("datos.parquet")
resultado = lazy.filter(pl.col("edad") > 18).select(["id", "edad", "diagnostico"])

# ===== Diagnóstico inicial =====
def diagnostico(df):
    print("=== DIAGNÓSTICO ===")
    print(f"Forma: {df.shape}")
    print(f"Memoria: {df.estimated_size('mb'):.2f} MB")
    print(f"
Tipos:
{df.dtypes}")
    print(f"
Nulos por columna:
{df.null_count()}")
    print(f"
Estadísticas:
{df.describe()}")

diagnostico(df)

```