

Analítica de Big Data | FACEN - Universidad Nacional de Asunción | 2026

Subnivel: 1.2 Entorno de trabajo: R/RStudio, archivos y lectura de datos

Microlectura: 1.2 Entorno de trabajo

1. Instalación y configuración

R se descarga desde cran.r-project.org. RStudio desde posit.co. Instalar en ese orden. Versiones mínimas recomendadas para el curso: $R \geq 4.3$, RStudio ≥ 2024.01 .

2. Estructura de un proyecto reproducible

```
mi_proyecto/  
  data/  
    raw/          ← datos originales, nunca modificar  
    processed/    ← datos limpios listos para análisis  
  scripts/  
    01_lectura.R  
    02_limpieza.R  
    03_analisis.R  
  outputs/  
    graficos/  
    tablas/  
  README.md
```

Esta estructura garantiza reproducibilidad: cualquier persona puede reproducir el análisis ejecutando los scripts en orden numérico.

3. Paquetes esenciales del curso

Paquete	Función principal	Instalación
data.table	Lectura y manipulación de datos grandes	<code>install.packages("data.table")</code>
arrow	Lectura/escritura de Parquet	<code>install.packages("arrow")</code>
readxl	Lectura de archivos Excel	<code>install.packages("readxl")</code>
jsonlite	Lectura/escritura de JSON	<code>install.packages("jsonlite")</code>
ggplot2	Visualización avanzada	<code>install.packages("ggplot2")</code>
dplyr	Manipulación de datos con sintaxis legible	<code>install.packages("dplyr")</code>

4. Formatos de archivo en detalle

CSV — Comma Separated Values

Formato universal, legible por cualquier herramienta. Desventaja: no guarda tipos de datos (todo se lee como texto inicialmente). Para archivos grandes, `fread()` de `data.table` es ~10x más rápido que `read.csv()`.

Parquet — El formato del Big Data

Almacenamiento columnar: guarda los datos por columna, no por fila. Ventajas:

- Compresión automática: un CSV de 5 GB puede ser 800 MB en Parquet.
- Lectura selectiva de columnas: si querés solo "edad" y "diagnostico", no lee las otras 50 columnas.
- Preserva tipos de datos: evita el problema de leer fechas como texto.