

Analítica de Big Data | FACEN - Universidad Nacional de Asunción | 2026

Subnivel: 1.3 Operaciones básicas, resúmenes y gráficos

Microlectura: 1.3 Operaciones básicas

1. El ciclo de exploración

Todo análisis de datos sigue un ciclo de 4 pasos:

1. **Preguntar:** ¿Qué quiero saber? (ej: ¿cuál región tiene mayor prevalencia de diabetes?)
2. **Filtrar/Agregar:** Seleccionar y resumir los datos necesarios.
3. **Visualizar:** Representar el patrón visualmente.
4. **Interpretar:** ¿Qué dice el dato? ¿Qué decisión informaría?

2. Operaciones en data.table (R)

La sintaxis de data.table es `dt[i, j, by]`:

- `i`: filas a seleccionar (filtro)
- `j`: columnas o cálculos a realizar
- `by`: variable de agrupación

Esta sintaxis concisa es extremadamente eficiente para datasets grandes.

3. Visualización con ggplot2

ggplot2 usa una "gramática de gráficos": cada gráfico se construye con capas:

1. `ggplot(data, aes(x=..., y=..., color=...))`: datos y mapeo estético
2. `geom_*()`: tipo de gráfico (`geom_histogram`, `geom_boxplot`, `geom_point`)

- 3. `labs()` : títulos y etiquetas
- 4. `theme_*()` : estilo visual

4. Estadísticas descriptivas clave

Medida	¿Para qué?	R	Python/Polars
Media	Tendencia central (sensible a outliers)	<code>mean(x)</code>	<code>pl.col("x").mean()</code>
Mediana	Tendencia central robusta	<code>median(x)</code>	<code>pl.col("x").median()</code>
Desvío estándar	Dispersión	<code>sd(x)</code>	<code>pl.col("x").std()</code>
Cuantiles	Distribución	<code>quantile(x, 0.25)</code>	<code>pl.col("x").quantile(0.25)</code>
Conteo	Frecuencias	<code>.N</code>	<code>pl.count()</code>