

2.1 Fundamentos de Visualización de Datos

1. Por qué visualizamos

John Tukey, padre del análisis exploratorio, decía que el propósito del análisis de datos era el *insight*, no los números. La visualización es el puente entre los datos crudos y la comprensión humana.

El célebre cuarteto de Anscombe ilustra por qué: cuatro datasets con medias, varianzas y correlaciones idénticas pero con distribuciones radicalmente distintas. Sin visualización, el analista concluiría que son iguales.

2. Gramática de Gráficos

Leland Wilkinson formalizó en 2005 los componentes de cualquier gráfico estadístico:

- **Datos:** el dataset que se mapea.
- **Estéticas (aes):** variables mapeadas a propiedades visuales (x, y, color, size, shape).
- **Geometrías (geom):** la representación visual (punto, línea, barra, área).
- **Estadísticas (stat):** transformaciones opcionales (conteo, suavizado, media).
- **Facetas:** subgráficos para subgrupos.
- **Coordenadas:** cartesianas, polares, proyecciones.
- **Tema:** apariencia no relacionada con datos.

ggplot2 en R implementa esta gramática directamente. Cada capa es una función que modifica el gráfico base.

3. Codificación visual efectiva

Cleveland y McGill (1984) establecieron la jerarquía de precisión perceptual:

1. Posición en escala común
2. Posición en escala no común
3. Longitud
4. Ángulo / pendiente
5. Área
6. Volumen / curvatura
7. Densidad / saturación de color

La regla práctica: usar posición o longitud para variables cuantitativas; color o forma para variables categóricas.

4. EDA: el proceso

El Análisis Exploratorio no tiene un protocolo rígido, pero sigue estas etapas:

1. **Univariado:** distribución de cada variable por separado (histogramas, boxplots, frecuencias).
2. **Bivariado:** relaciones entre pares de variables (dispersión, correlación, tablas cruzadas).
3. **Multivariado:** patrones entre 3+ variables (matrices de dispersión, heatmaps de correlación).
4. **Anomalías:** identificar outliers, valores faltantes, inconsistencias.
5. **Hipótesis:** formular preguntas que el análisis confirmatorio responderá.

5. Errores comunes

- Eje Y que no empiece en cero en barras (exagera diferencias)
- Pie charts con más de 5 categorías (ilegible)
- 3D innecesario (distorsiona percepción)
- Paletas de color no aptas para daltónicos

- Demasiada información en un solo gráfico

6. Buenas prácticas

Usar paletas accesibles (viridis, ColorBrewer). Siempre incluir título, ejes etiquetados y fuente de datos. Para audiencias no técnicas, preferir gráficos simples y anotaciones explicativas sobre sofisticación visual.