

2.2 Aplicación: Pipeline de Calidad de Datos en Producción

Contexto

Una empresa de telecomunicaciones en Paraguay requiere un pipeline automático que evalúe la calidad de datos de sus archivos de facturación antes de cargarlos a su data warehouse.

Función de auditoría automática

```
library(dplyr)

auditar_dataset <- function(df, nombre = "Dataset") {
  cat(sprintf("
=== AUDITORÍA: %s ===
", nombre))
  cat(sprintf("Dimensiones: %d filas x %d columnas
", nrow(df), ncol(df)))

  # Análisis por columna
  for (col in names(df)) {
    x <- df[[col]]
    nas <- sum(is.na(x))
    pct_nas <- round(nas/length(x)*100, 1)

    if (is.numeric(x)) {
      Q1 <- quantile(x, 0.25, na.rm=TRUE)
      Q3 <- quantile(x, 0.75, na.rm=TRUE)
      outliers <- sum(x < Q1 - 1.5*(Q3-Q1) | x > Q3 + 1.5*(Q3-Q1), na.rm=TRUE)
      cat(sprintf("  %s: %.1f±%.1f [min=%.1f, max=%.1f] | NAs: %d (%.1f%%) | Outliers: %d
",
                  col, mean(x,na.rm=T), sd(x,na.rm=T), min(x,na.rm=T), max(x,na.rm=T),

```

```
      nas, pct_nas, outliers))
    } else {
      niveles <- length(unique(na.omit(x)))
      cat(sprintf("  %s: %d categorías | NAs: %d (%.1f%%)
",
      col, niveles, nas, pct_nas))
    }
  }

  dupes <- sum(duplicated(df))
  cat(sprintf("Duplicados: %d (%.1f%%)
", dupes, dupes/nrow(df)*100))
}

# Uso
set.seed(42)
facturacion <- data.frame(
  cliente_id = sample(1:1000, 500, replace=TRUE),
  monto_gs = c(rnorm(490, 250000, 80000), rep(NA, 5), c(5000000, -1000, 0, 100, 200)),
  fecha = sample(seq(as.Date("2024-01-01"), as.Date("2024-12-31"), by="day"), 500, replace=TRUE),
  servicio = sample(c("Fibra", "4G", "5G"), 500, replace=TRUE)
)

auditar_dataset(facturacion, "Facturación 2024")
```

Extensión: Modificar la función para que genere un reporte HTML automático con `rmarkdown::render()` que pueda enviarse por email al equipo de datos.