

2.2 Estadísticos Descriptivos y Limpieza de Datos

1. El ciclo de datos sucios

Se estima que los científicos de datos dedican entre el 60% y el 80% de su tiempo a limpiar y preparar datos. Los datos "sucios" incluyen: valores faltantes (NA/NaN), tipos incorrectos, duplicados, outliers, inconsistencias de formato y codificaciones erróneas.

Un dato sucio no detectado puede invalidar todo un análisis. La regla de oro: nunca confiar en datos sin haberlos explorado con estadísticos descriptivos y visualizaciones.

2. Estadísticos descriptivos: el resumen numérico

Los estadísticos descriptivos se dividen en cuatro grupos:

- **Tendencia central:** dónde está el "centro" de los datos (media, mediana, moda).
- **Dispersión:** cuánto se alejan los datos del centro (varianza, SD, IQR, rango).
- **Forma:** asimetría (skewness) y curtosis (kurtosis) de la distribución.
- **Posición:** cuartiles, percentiles, valores extremos.

En R, `summary(df)` entrega los 6 números de Tukey para cada variable numérica: mínimo, Q1, mediana, media, Q3, máximo.

3. Distribuciones asimétricas

Cuando la distribución es simétrica, $\text{media} \approx \text{mediana}$. Cuando hay sesgo positivo (cola derecha larga, como ingresos), $\text{media} > \text{mediana}$: la media es "jalada" por los valores extremos. En ese caso, la mediana es más representativa del "centro".

Ejemplo: Si 9 personas ganan 2.000.000 Gs y 1 persona gana 50.000.000 Gs, la media sería 6.800.000 Gs — muy alejada de lo que gana la mayoría. La mediana de 2.000.000 Gs es más informativa.

4. La regla de Tukey para outliers

John Tukey definió los "bigotes" del boxplot: los valores que caen fuera de $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ se consideran outliers. Para distribuciones normales, esto captura $\approx 0.7\%$ de los datos como outliers.

Los outliers pueden ser: errores de captura (hay que corregirlos), valores legítimos raros (hay que investigarlos), o señales importantes (¡hay que analizarlos!).

5. Normalización vs estandarización

Min-Max (normalización): transforma a rango $[0,1]$: $x_{\text{norm}} = (x - \min) / (\max - \min)$. Sensible a outliers.

Z-score (estandarización): transforma a $\text{media}=0$, $\text{sd}=1$: $z = (x - \mu) / \sigma$. Más robusta, necesaria para algoritmos que asumen distribución normal o que comparan distancias (KNN, regresión logística, LDA).

6. Imputación de valores faltantes

Estrategias según el tipo de missingness:

- **MCAR** (Missing Completely At Random): cualquier estrategia funciona; la más simple es omitir.
- **MAR** (Missing At Random): imputar con la media/mediana del grupo correspondiente.

- **MNAR** (Missing Not At Random): requiere modelos de imputación sofisticados (mice, KNN imputer).