

## 2.2 Práctica Guiada: Limpieza de Dataset de Ventas

**Duración:** 50 minutos | **Herramienta:** R + dplyr

### Ficha 1: Crear dataset con problemas

```
set.seed(100)
ventas <- data.frame(
  fecha = sample(seq(as.Date("2023-01-01"), as.Date("2023-12-31"), by="day"), 300, replace=TRUE),
  producto = sample(c("A","B","C","a","b"), 300, replace=TRUE),
  cantidad = c(rpois(295, 50), -5, NA, NA, 500, 480),
  precio = c(round(rnorm(295, 15000, 3000)), 0, NA, 999999, 14500, 16000),
  vendedor = sample(paste0("V", 1:10), 300, replace=TRUE)
)
# Agregar duplicados
ventas <- rbind(ventas, ventas[c(10,20,30),])
```

Responde: ¿Qué problemas identificás a simple vista?

### Ficha 2: Auditoría inicial

```
library(dplyr)
summary(ventas)
colSums(is.na(ventas))
```

```
sum(duplicated(ventas))  
# ¿Cuántos NAs hay en precio? ¿Y en cantidad?  
# ¿Cuántos duplicados?  
# ¿Los valores de 'producto' son consistentes?
```

## Ficha 3: Limpieza paso a paso

```
ventas_clean <- ventas %>%  
  distinct() %>%                                # Paso 1: eliminar duplicados  
  mutate(  
    producto = toupper(producto),                # Paso 2: normalizar texto  
    precio = na_if(precio, 0),                  # Paso 3: ceros → NA  
    precio = na_if(precio, 999999)              # outlier extremo → NA  
  ) %>%  
  mutate(  
    precio = ifelse(is.na(precio), median(precio, na.rm=TRUE), precio),  
    cantidad = ifelse(is.na(cantidad) | cantidad < 0, median(cantidad, na.rm=TRUE), cantidad)  
  ) %>%  
  filter(producto %in% c("A","B","C"))          # Paso 4: categorías válidas
```

Verifica: `summary(ventas_clean)` — ¿quedan NAs? ¿El rango de precio es razonable?

## Ficha 4: Análisis post-limpieza

```
ventas_clean %>%  
  group_by(producto, vendedor) %>%  
  summarise(  
    total_ventas = sum(cantidad * precio),  
    n_transacciones = n(),  
    .groups = "drop"  
  ) %>%  
  arrange(desc(total_ventas))
```

¿Cuál es el producto más vendido? ¿Qué vendedor genera más ingresos?