

2.2 Estadísticos Descriptivos y Limpieza de Datos — Resumen

Los estadísticos descriptivos resumen numéricamente las características de un dataset. La limpieza de datos (data cleaning) garantiza que el análisis se realice sobre datos fiables.

Medidas de tendencia central

Medida	Función R	Función Python	Cuándo usar
Media	mean(x)	x.mean()	Distribuciones simétricas
Mediana	median(x)	x.median()	Con outliers o distribuciones sesgadas
Moda	table(x) → max	x.mode()[0]	Variables categóricas

Medidas de dispersión

- **Varianza:** $\text{var}(x)$ — promedio de desviaciones cuadráticas
- **Desvío estándar:** $\text{sd}(x)$ — raíz de la varianza, misma unidad que x
- **Rango intercuartílico (IQR):** $\text{IQR}(x) = Q3 - Q1$, robusto a outliers
- **Coefficiente de variación:** $\text{sd}/\text{mean} \times 100$ — dispersión relativa

Detección de outliers

Regla de Tukey: outlier si $x < Q1 - 1.5 \times \text{IQR}$ o $x > Q3 + 1.5 \times \text{IQR}$. Z-score: outlier si $|z| > 3$.

Limpieza de datos

- **Valores faltantes:** omitir (`na.rm=TRUE`), imputar media/mediana/KNN
- **Tipos incorrectos:** `as.numeric()`, `as.factor()`, `as.Date()`
- **Duplicados:** `duplicated()`, `distinct()` en `dplyr`
- **Normalización:** escala 0-1 (min-max) o Z-score (media=0, sd=1)