

2.3 Aplicación: Análisis de Correlación para Selección de Features

Contexto

Antes de entrenar un modelo de Machine Learning, es fundamental analizar las correlaciones entre variables. Variables altamente correlacionadas (multicolinealidad) pueden causar inestabilidad en los modelos de regresión. El análisis de correlación permite seleccionar un subconjunto óptimo de features.

Pipeline de selección de features por correlación

```
library(dplyr)
library(corrplot)
library(caret)

# Datos de ejemplo: calidad de vino
wine <- read.csv("https://archive.ics.uci.edu/ml/machine-learning-databases/wine-quality/winequality-red",
  sep = ";")

# 1. Matriz de correlación con la variable objetivo
cor_with_quality <- cor(wine)[,"quality"]
print(sort(cor_with_quality, decreasing = TRUE))

# 2. Detectar variables altamente correlacionadas entre sí
cor_matrix <- cor(wine %>% select(-quality))
high_cor <- findCorrelation(cor_matrix, cutoff = 0.75, names = TRUE)
cat("Variables altamente correlacionadas (r > 0.75):", paste(high_cor, collapse=" ", "
")

# 3. Eliminar variables redundantes
wine_filtered <- wine %>% select(-all_of(high_cor))
```

```
cat("Variables seleccionadas:", ncol(wine_filtered) - 1, "  
")  
  
# 4. Visualizar correlaciones restantes  
corrplot(cor(wine_filtered),  
          method = "color", type = "upper",  
          addCoef.col = "black", number.cex = 0.7,  
          title = "Correlaciones post-selección")
```

Principio: Si dos variables tienen $r > 0.75$, en general se puede eliminar una sin perder información significativa. La elección de cuál eliminar depende de la interpretabilidad y la correlación con la variable objetivo.