

2.3 Correlación y Análisis de Agrupación

1. El coeficiente de correlación de Pearson

El coeficiente r de Pearson cuantifica la fuerza y dirección de la *relación lineal* entre dos variables cuantitativas. Se calcula como la covarianza estandarizada:

$$r = \frac{\sum[(x_i - \bar{x})(y_i - \bar{y})]}{\sqrt{[\sum(x_i - \bar{x})^2 \times \sum(y_i - \bar{y})^2]}}$$

Valores de r van de -1 a $+1$. Un r de 0.85 indica una correlación positiva fuerte; -0.60 indica correlación negativa moderada.

2. La trampa de la correlación

Existen "correlaciones espurias" históricamente documentadas: el consumo de queso per cápita en EE.UU. correlaciona $r=0.95$ con muertes por enredarse en sábanas. Claramente no hay causalidad: ambas crecen con el tiempo (variable confusora: año).

La regla: correlación es necesaria pero no suficiente para causalidad. Para establecer causalidad se necesitan experimentos controlados o métodos de inferencia causal (diferencias en diferencias, variables instrumentales).

3. Cuando Pearson falla

Pearson asume que la relación es lineal. Si la relación es curvilínea (ej: rendimiento académico vs nivel de estrés en forma de U invertida), Pearson puede dar $r \approx 0$ aunque la relación sea fuerte.

Alternativas: Spearman (rangos, robusta a no-linealidad monótona), Kendall (concordancia de pares), o simplemente graficar el scatterplot antes de reportar r .

4. Matrices de correlación

Con múltiples variables, se calcula la correlación entre todos los pares y se organiza en una matriz simétrica. El heatmap de correlación visualiza esta matriz usando color. Util para:

- Detectar variables altamente correlacionadas (multicolinealidad)
- Seleccionar features para modelos
- Descubrir grupos de variables que se mueven juntas

5. Análisis de agrupación (GroupBy)

El análisis por grupos permite responder preguntas como "¿cuál es el ingreso promedio por departamento?" o "¿cuántas ventas se hacen por producto por mes?". El flujo:

1. **group_by(variable):** segmenta el dataset por categorías.
2. **summarise(...):** calcula estadísticos dentro de cada grupo.
3. **arrange(desc(métrica)):** ordena por la métrica calculada.

En datos grandes con data.table: `dt[, .(media = mean(valor)), by = grupo]` es mucho más rápido que el equivalente en dplyr.

6. Tablas de contingencia y chi-cuadrado

Para variables categóricas, la tabla de contingencia cuenta las combinaciones. El test chi-cuadrado prueba si las dos variables son independientes. Un p-valor < 0.05 sugiere que hay asociación estadística entre las variables.