

2.3 Procedimiento: Análisis de Correlación y Agrupación

Objetivo

Identificar relaciones entre variables mediante correlación y resumir patrones por grupos en un dataset multivariado.

Pasos

Paso 1: Cargar datos y seleccionar variables

```
library(dplyr); library(ggplot2); library(corrplot)
data("diamonds", package = "ggplot2")
# Solo variables numéricas
num_vars <- diamonds %>% select(carat, depth, table, price, x, y, z)
summary(num_vars)
```

Paso 2: Calcular matriz de correlación

```
cor_mat <- cor(num_vars, use = "complete.obs")
print(round(cor_mat, 3))
# ¿Qué variable correlaciona más con price?
```

Paso 3: Visualizar

```
corrplot(cor_mat,
  method = "color",
```

```

type = "upper",
addCoef.col = "black",
number.cex = 0.75,
tl.cex = 0.8,
col = colorRampPalette(c("#053061", "white", "#67001F"))(200),
title = "Correlaciones – diamonds",
mar = c(0,0,1,0))

```

Paso 4: Scatterplot de la correlación más alta

```

ggplot(diamonds, aes(x = carat, y = price, color = cut)) +
  geom_point(alpha = 0.2, size = 1) +
  geom_smooth(method = "lm", se = FALSE) +
  scale_color_brewer(palette = "Spectral") +
  labs(title = sprintf("carat vs price (r = %.3f)",
                      cor(diamonds$carat, diamonds$price)),
       x = "Quilates", y = "Precio (USD)") +
  theme_minimal()

```

Paso 5: Análisis de agrupación

```

diamonds %>%
  group_by(cut, color) %>%
  summarise(
    n = n(),
    precio_medio = mean(price),
    precio_mediana = median(price),
    carat_medio = mean(carat),
    .groups = "drop"
  ) %>%
  arrange(desc(precio_medio)) %>%
  head(10)

```

Paso 6: Visualizar grupos

```

ggplot(diamonds, aes(x = cut, y = price, fill = cut)) +
  geom_violin(trim = FALSE) +
  geom_boxplot(width = 0.1, fill = "white", outlier.size = 0.5) +
  scale_y_log10(labels = scales::dollar) +
  scale_fill_brewer(palette = "Set2") +
  labs(title = "Distribución de precios por calidad de corte") +
  theme_minimal() + theme(legend.position = "none")

```