

2.3 Correlación y Análisis de Agrupación

— Resumen

El análisis de correlación mide la fuerza y dirección de la relación lineal entre dos variables. El análisis de agrupación (groupby) resume datasets por categorías para obtener métricas por segmento.

Correlación de Pearson

$r = \text{Cov}(X,Y) / (\sigma_X \times \sigma_Y)$, donde $r \in [-1, 1]$.

- $r = 1$: correlación positiva perfecta
- $r = 0$: sin correlación lineal
- $r = -1$: correlación negativa perfecta
- $|r| > 0.7$: fuerte; $0.4-0.7$: moderada; < 0.4 : débil

Correlación $\neq$ Causalidad: Variables pueden correlacionar por coincidencia o por una variable confusora común.

Correlación de Spearman

Alternativa no paramétrica: mide correlación entre los *rangos* de las variables. Más robusta a outliers y para variables ordinales.

Agrupación con dplyr

```
df %>%
  group_by(categoria) %>%
  summarise(
    n = n(),
    media = mean(valor),
    sd = sd(valor),
    mediana = median(valor)
  )
```

Tabla cruzada (contingencia)

Para variables categóricas: `table(df$var1, df$var2)` o `crosstab` en Python. Chi-cuadrado prueba independencia.