

3.1 Aplicación: Detección de Clientes en Riesgo de Mora

Contexto

Un banco en Paraguay quiere predecir qué clientes podrían caer en mora antes de los 90 días. Se dispone de datos históricos de clientes con sus características y el resultado final (mora: sí/no).

Simulación del dataset

```
set.seed(99)
n <- 1000
clientes <- data.frame(
  edad = round(rnorm(n, 38, 10)),
  ingresos_millones = round(rexp(n, 0.5) + 1, 2),
  deuda_actual = round(runif(n, 0, 5000000)),
  antiguedad_anos = round(rexp(n, 0.3)),
  num_prestamos = rpois(n, 1.5),
  mora = factor(sample(c("Si", "No"), n, replace=TRUE, prob=c(0.25, 0.75)))
)
table(clientes$mora) # Dataset desbalanceado
```

Pipeline KNN con manejo de desbalance

```
library(caret); library(class)
set.seed(42)
idx <- createDataPartition(clientes$mora, p=0.8, list=FALSE)
train <- clientes[idx,]; test <- clientes[-idx,]
```

```
# Normalizar
pp <- preProcess(train[,1:5], method=c("center","scale"))
train_n <- predict(pp, train[,1:5])
test_n  <- predict(pp, test[,1:5])

# Evaluar con varias métricas
pred <- knn(train_n, test_n, train$mora, k=9)
cm <- confusionMatrix(pred, test$mora, positive="Si")
print(cm)

# Métricas clave para desbalance:
cat("Sensitivity (Recall):", cm$byClass["Sensitivity"], "
")
cat("Precision:", cm$byClass["Precision"], "
")
cat("F1-Score:", cm$byClass["F1"], "
")
```

Nota real: En problemas de detección de mora/fraude, la clase minoritaria (mora=Sí) es la más importante. La accuracy puede ser 75% prediciendo siempre "No". Usar Recall o F1 como métrica objetivo.

Estrategia de umbral variable

```
nb <- naiveBayes(mora ~ ., data=train)
probs <- predict(nb, test, type="raw")[,"Si"]
# Probar distintos umbrales
for (umbral in c(0.3, 0.4, 0.5, 0.6)) {
  pred_umbral <- factor(ifelse(probs >= umbral, "Si", "No"), levels=c("No","Si"))
  cm_u <- confusionMatrix(pred_umbral, test$mora, positive="Si")
  cat(sprintf("Umbral %.1f: Recall=%.3f, Precision=%.3f
",
              umbral, cm_u$byClass["Sensitivity"], cm_u$byClass["Precision"]))
}
```