

3.1 KNN y Naive Bayes

1. La intuición detrás de KNN

"Dime con quién andas y te diré quién eres." Esta frase resume KNN: un punto desconocido se clasifica por la mayoría de sus K vecinos más cercanos en el espacio de features.

El algoritmo funciona en tres pasos: (1) calcular la distancia entre el punto nuevo y todos los puntos de entrenamiento, (2) seleccionar los K puntos más cercanos, (3) asignar la clase más frecuente entre esos K vecinos.

No hay ecuación que "aprender": el modelo es el conjunto de datos de entrenamiento. Por eso se llama "lazy learner" — no aprende durante el entrenamiento pero trabaja duro al predecir.

2. La elección de K

K es el hiperparámetro más crítico de KNN. Si $K=1$, el modelo es muy sensible al ruido — un outlier puede clasificar mal un punto cercano (overfitting). Si $K=n$ (todos los vecinos), siempre predice la clase mayoritaria global (underfitting).

La regla empírica es $K = \sqrt{n}$, donde n es el tamaño del dataset. En la práctica, se usa validación cruzada para seleccionar el K óptimo probando varios valores y eligiendo el que minimiza el error de clasificación.

3. Por qué normalizar es obligatorio en KNN

Si un dataset tiene "edad" (rango 0-100) y "salario" (rango 0-10,000,000), sin normalizar la distancia euclidiana estará dominada por el salario. Un punto con misma edad pero diferente

salario será "lejano" aunque conceptualmente sean similares.

La solución: escalar todas las features al mismo rango con Min-Max o Z-score antes de aplicar KNN. Esto garantiza que cada variable contribuya equitativamente a la distancia.

4. El teorema de Bayes y Naive Bayes

El teorema de Bayes actualiza la probabilidad de una hipótesis dado nueva evidencia:

$$P(H|E) = P(E|H) \times P(H) / P(E)$$

En clasificación: H es la clase, E son los features. P(H) es la probabilidad a priori (frecuencia de cada clase). P(E|H) es la verosimilitud (cómo se distribuyen los features dado la clase). P(H|E) es la probabilidad a posteriori que queremos maximizar.

5. La suposición "naive"

El nombre "naive" (ingenuo) viene de la suposición de independencia condicional: dados la clase, todos los features son independientes entre sí. Esto raramente es cierto — por ejemplo, en un email, las palabras "promoción" y "oferta" no son independientes. Sin embargo, el algoritmo funciona sorprendentemente bien en la práctica incluso violando este supuesto.

Caso de uso clásico: Filtro de spam. Naive Bayes calcula la probabilidad de spam dado las palabras del email, y la de no-spam dado las mismas palabras. Clasifica como spam si $P(\text{spam}|\text{palabras}) > P(\text{no-spam}|\text{palabras})$.

6. Evaluación de modelos de clasificación

Métricas clave: Accuracy, Precision, Recall, F1-Score, y la Matriz de Confusión. Para datasets desbalanceados, la accuracy puede ser engañosa — si el 95% son clase A, predecir siempre A da 95% accuracy pero 0% utilidad.