

3.2 Regresión Logística

1. ¿Por qué no usar regresión lineal para clasificar?

La regresión lineal predice valores en $(-\infty, +\infty)$, pero una probabilidad debe estar en $[0,1]$. Si aplicamos regresión lineal directamente, podemos obtener predicciones como -0.3 o 1.7 — sin sentido como probabilidades.

Además, la regresión lineal asume distribución normal de los residuos, lo cual no se cumple cuando la variable de respuesta es binaria (0/1).

2. La función sigmoide: el puente

La solución es transformar la combinación lineal de features ($z = X\beta$) con la función sigmoide:

$$P(Y=1|X) = \sigma(z) = 1 / (1 + e^{-z})$$

La sigmoide tiene propiedades perfectas para este propósito: siempre produce valores en $(0,1)$, tiene derivada continua (necesaria para el gradiente), y es monótonamente creciente (preserva el orden relativo de predicciones).

3. El umbral de decisión

Por defecto, se clasifica como clase 1 si $P(Y=1|X) \geq 0.5$. Pero este umbral se puede ajustar según el contexto del problema. Un umbral de 0.3 en detección de fraude significa que clasificamos como fraudulenta cualquier transacción con más del 30% de probabilidad — preferimos falsos positivos a falsos negativos.

4. Interpretación de coeficientes

En regresión logística, los coeficientes β no son directamente interpretables en la escala de la probabilidad. En cambio, $\exp(\beta)$ es el *odds ratio*:

- $\exp(\beta) = 2 \rightarrow$ el odds de clase 1 se duplica por cada unidad de aumento en x .
- $\exp(\beta) = 0.5 \rightarrow$ el odds se reduce a la mitad.
- $\exp(\beta) = 1 \rightarrow$ la variable no tiene efecto en el odds.

Ejemplo: En un modelo de mora bancaria, si $\beta_{\text{edad}} = 0.05$, entonces $\exp(0.05) \approx 1.05$: por cada año más de edad, el odds de caer en mora aumenta un 5%.

5. Regularización: combatir el overfitting

Sin regularización, modelos con muchas variables pueden sobreajustarse. La regularización agrega una penalización por coeficientes grandes a la función de pérdida:

- **L2 (Ridge):** penaliza $\sum \beta_i^2$ — reduce todos los coeficientes proporcionalmente.
- **L1 (Lasso):** penaliza $\sum |\beta_i|$ — puede hacer algunos β exactamente cero (selección automática de variables).

6. Supuestos de la regresión logística

No requiere normalidad de los errores (como sí requiere la regresión lineal). Sí requiere: ausencia de multicolinealidad fuerte, linealidad en el log-odds (relación lineal entre X y $\log[p/(1-p)]$), y observaciones independientes. Es sensible a outliers extremos.