

3.3 Aplicación: Pipeline Automático de Selección de Modelos

Contexto

Un científico de datos de una empresa de seguros en Paraguay necesita seleccionar el mejor clasificador para predecir siniestros. Se construye un pipeline automático que entrena, evalúa y reporta todos los modelos.

Pipeline automático

```
library(caret); library(MASS); library(pROC)

benchmark_clasificadores <- function(datos, var_objetivo, seed=42) {
  set.seed(seed)
  cat("=== BENCHMARK DE CLASIFICADORES ===")
  cat("Dataset:", nrow(datos), "filas |", ncol(datos)-1, "features")
  cat("Distribución de clases:")
  print(table(datos[[var_objetivo]]))

  formula <- as.formula(paste(var_objetivo, "~ ."))
  ctrl <- trainControl(method="cv", number=10,
                      savePredictions="final",
                      classProbs=TRUE)

  modelos <- list(
    LDA = list(method="lda", preProcess=c("center","scale")),
    KNN = list(method="knn", preProcess=c("center","scale"), tuneLength=10),
    NB = list(method="naive_bayes"),
    RL = list(method="glm", family="binomial", preProcess=c("center","scale"))
```

```
)

resultados_cv <- list()
for (nombre in names(modelos)) {
  args <- c(list(form=formula, data=datos, trControl=ctrl), modelos[[nombre]])
  m <- do.call(train, args)
  resultados_cv[[nombre]] <- m
  cat(sprintf("  %s: %.4f ± %.4f\n", nombre,
              max(m$results$Accuracy), sd(m$results$Accuracy)))
}

res <- resamples(resultados_cv)
mejor <- names(which.max(sapply(resultados_cv, function(m) max(m$results$Accuracy))))
cat("
Mejor modelo:", mejor, "
")

list(modelos=resultados_cv, resamples=res, mejor=mejor)
}

# Uso
data(PimaIndiansDiabetes, package="mlbench")
resultado <- benchmark_clasificadores(PimaIndiansDiabetes, "diabetes")
bwplot(resultado$resamples, metric="Accuracy")
```

Extensión: Agregar al pipeline la generación automática de un informe PDF con rmarkdown que incluya métricas, gráficos de comparación y recomendación del modelo, para distribuir al equipo de negocio.