

MATERIAL DE LECTURA — UNIDAD 1

ANALÍTICA DE BIG DATA

Introducción al manejo de datos en Big Data

FACULTAD DE CIENCIAS EXACTAS Y NATURALES
UNIVERSIDAD NACIONAL DE ASUNCIÓN
Carrera: Matemática Estadística



CONTENIDOS DE LA UNIDAD 1

Este material de lectura acompaña los contenidos trabajados en la primera unidad. Al finalizar su estudio, el estudiante habrá comprendido los fundamentos del Big Data, dominará el entorno R/RStudio y estará en condiciones de realizar análisis exploratorios y visualizaciones básicas sobre conjuntos de datos reales.

1. ¿Qué es el Big Data? Orígenes y características

- ▶ Las 5V del Big Data
- ▶ Big Data vs. datos tradicionales
- ▶ Aplicaciones en el mundo real

2. Ecosistema y herramientas de la Analítica de Big Data

- ▶ Lenguajes: R y Python
- ▶ Plataformas: Hadoop, Spark
- ▶ Flujo típico de un proyecto de datos

3. Instalación y configuración de R y RStudio

- ▶ Descarga e instalación de R (CRAN)
- ▶ Instalación de RStudio Desktop
- ▶ Verificación del entorno

4. El entorno RStudio: partes y funciones

- ▶ Panel de consola
- ▶ Editor de scripts
- ▶ Ambiente y panel de archivos
- ▶ Panel de gráficos/paquetes

5. Operaciones básicas en R

- ▶ Tipos de datos y estructuras
- ▶ Vectores, matrices y data frames
- ▶ Funciones esenciales

6. Importación y exploración inicial de datos

- ▶ Lectura de CSV y Excel
- ▶ Inspección con `head()`, `str()`, `summary()`
- ▶ Detección de valores perdidos

7. Visualización con R base y ggplot2

- ▶ Gráficos con `plot()`, `hist()`, `boxplot()`
- ▶ Introducción a ggplot2
- ▶ Capas y estética

8. Buenas prácticas y reproducibilidad

- ▶ Organización de proyectos
- ▶ Comentarios y documentación
- ▶ Control de versiones básico

9. Referencias y recursos

- ▶ Bibliografía básica
- ▶ Tutoriales en línea
- ▶ Comunidades de R

1. ¿QUÉ ES EL BIG DATA? ORÍGENES Y CARACTERÍSTICAS

El término Big Data hace referencia a conjuntos de datos de una dimensión y complejidad tan grandes que los sistemas de procesamiento y almacenamiento de datos tradicionales son insuficientes para capturarlos, almacenarlos, gestionarlos y analizarlos. El concepto empezó a ganar prominencia a principios del siglo XXI, impulsado por el crecimiento explosivo de Internet, las redes sociales, los dispositivos móviles y los sensores conectados (Internet de las Cosas, IoT).

Hoy en día se estima que se generan más de 2,5 quintillones de bytes de datos por día a nivel global. Esta avalancha de información proviene de transacciones bancarias, publicaciones en redes sociales, registros médicos, imágenes satelitales, logs de servidores, señales GPS y miles de fuentes adicionales.

1.1 Las 5V del Big Data

La literatura académica y técnica describe el Big Data mediante un conjunto de dimensiones características, popularmente conocidas como las '5V'. Cada una representa un desafío diferente al que se enfrenta quien trabaja con estos datos:

Tabla 1. Las 5V del Big Data

Las cinco dimensiones que definen y caracterizan los entornos de Big Data.

Dimensión (V)	Descripción	Ejemplo
Volumen	Cantidad masiva de datos generados y almacenados.	Petabytes o exabytes de registros diarios en plataformas como YouTube, Facebook.
Velocidad	Rapidez con que se generan, transmiten y procesan los datos.	Streams en tiempo real de bolsas de valores, sensores IoT.
Variedad	Diversidad de formatos: estructurados, semi-estructurados y no estructurados.	Texto, imágenes, audio, video, JSON, XML, tablas relacionales.
Veracidad	Grado de confiabilidad, calidad y precisión de los datos.	Ruido en sensores, datos incompletos, sesgos de muestreo.
Valor	Capacidad de extraer información útil y accionable.	Modelos predictivos, sistemas de recomendación, detección de fraude.

💡 Concepto clave: no se trata solo del tamaño de los datos, sino de la capacidad de extraer valor de ellos de forma eficiente. Un terabyte de datos sin análisis no produce ninguna ventaja competitiva; la analítica es el puente entre los datos y las decisiones.

1.2 Big Data vs. datos tradicionales

Tabla 2. Comparación: Datos tradicionales vs. Big Data

Aspecto	Datos Tradicionales	Big Data
Escala	Miles de filas (GB)	Millones-billones (TB-PB)
Estructura	Tabular (SQL)	Mixta: SQL, NoSQL, texto, multimedia
Velocidad	Procesamiento batch	Tiempo real, streaming
Herramientas	Excel, SPSS, Stata	R, Python, Spark, Hadoop, Kafka
Almacenamiento	Servidor local o BD relacional	Data lake, Data warehouse, nube
Análisis	Descriptivo e inferencial	Machine Learning, Deep Learning

1.3 Aplicaciones de la Analítica de Big Data

La analítica de Big Data tiene aplicaciones en prácticamente todos los sectores. Algunos ejemplos destacados incluyen:

- Salud: análisis genómico, epidemiología, sistemas de alerta temprana de brotes.
- Finanzas: detección de fraude en tiempo real, modelos de riesgo crediticio.
- Comercio: motores de recomendación (Netflix, Amazon), análisis de comportamiento.
- Transporte: optimización de rutas, tráfico en tiempo real, vehículos autónomos.
- Agro: modelos predictivos de rendimiento de cultivos, monitoreo satelital.
- Gobierno: análisis de redes sociales, optimización de servicios públicos.

2. ECOSISTEMA Y HERRAMIENTAS DE LA ANALÍTICA DE BIG DATA

El ecosistema de herramientas disponibles para la Analítica de Big Data es amplio y está en constante evolución. Las principales categorías son: lenguajes de programación y análisis, plataformas de procesamiento distribuido, bases de datos especializadas, herramientas de visualización y plataformas en la nube.

2.1 Lenguajes principales: R y Python

R y Python son los dos lenguajes de programación más utilizados en ciencia de datos y analítica. Aunque comparten muchas capacidades, tienen orientaciones diferentes:

Tabla 3. R vs. Python para Analítica de Datos

Aspecto	R	Python
Origen	Bell Labs, 1993. Murray Hill, NJ.	Guido van Rossum, 1991. Países Bajos.
Orientación	Estadística y análisis de datos.	Programación general + ciencia de datos.
Fortalezas	Estadística avanzada, visualización.	Machine Learning, producción, versatilidad.
Ecosistema clave	tidyverse, ggplot2, caret, Shiny.	pandas, scikit-learn, TensorFlow, PyTorch.
Entorno IDE	RStudio.	Jupyter, VS Code, PyCharm.
Curva de aprendizaje	Moderada para estadísticos.	Moderada para programadores.

✍ En este curso usaremos principalmente R y RStudio, complementando con Python en unidades posteriores. Ambos lenguajes son gratuitos, de código abierto y ampliamente usados en el sector académico y profesional.

2.2 Plataformas de procesamiento: Hadoop y Spark

Cuando los datos superan la capacidad de una sola máquina, se recurre a plataformas de procesamiento distribuido. Los más conocidos son:

- Apache Hadoop: framework de código abierto que permite el procesamiento distribuido de grandes conjuntos de datos usando clusters de computadoras. Basa su modelo en MapReduce — dividir el trabajo en tareas paralelas.
- Apache Spark: motor de procesamiento analítico de uso general, más rápido que Hadoop para muchas tareas. Soporta R (SparkR, sparklyr) y Python (PySpark).

2.3 Flujo típico de un proyecto de analítica de datos

Independientemente del tamaño de los datos y las herramientas elegidas, un proyecto de analítica sigue un ciclo de vida estándar:

1. Definición del problema y objetivos del análisis.
2. Recopilación y adquisición de datos (APIs, web scraping, bases de datos, sensores).
3. Preparación y limpieza de datos (imputación, normalización, codificación).
4. Análisis exploratorio de datos (EDA): estadísticas descriptivas y visualizaciones.
5. Modelado: aplicación de algoritmos estadísticos o de Machine Learning.
6. Evaluación y validación del modelo.
7. Comunicación de resultados (informes, dashboards, APIs).
8. Despliegue y monitoreo en producción.

3. INSTALACIÓN Y CONFIGURACIÓN DE R Y RSTUDIO

Para comenzar a trabajar con R es necesario instalar dos componentes: el lenguaje R en sí mismo (que se descarga desde el repositorio CRAN) y RStudio, que es el entorno de desarrollo integrado (IDE) que facilita enormemente el trabajo.

3.1 Instalación de R

1. Ir a <https://cran.r-project.org/>
2. Seleccionar el sistema operativo: Windows, macOS o Linux.
3. Descargar el instalador base (p. ej. R-4.4.x-win.exe para Windows).
4. Ejecutar como administrador y seguir el asistente (opciones por defecto son correctas).
5. Verificar la instalación: abrir R y escribir version en la consola.

 Nota: se recomienda instalar PRIMERO R y DESPUÉS RStudio. RStudio detecta automáticamente la versión de R instalada en el sistema.

3.2 Instalación de RStudio

1. Ir a <https://posit.co/download/rstudio-desktop/>
2. Descargar la versión gratuita: RStudio Desktop (Open Source).
3. Ejecutar el instalador y aceptar la configuración predeterminada.
4. Abrir RStudio: debería detectar R automáticamente.
5. Verificar en la consola de RStudio: escribir R.version.string

3.3 Instalación de paquetes esenciales

Una vez instalado R y RStudio, se recomienda instalar los paquetes del ecosistema tidyverse y otras librerías necesarias para el curso. Ejecutar en la consola de R:

[R]

```
# Instalar el ecosistema tidyverse (incluye ggplot2, dplyr, tidyr, readr, etc.)
install.packages("tidyverse")

# Paquetes adicionales para Big Data y Machine Learning
install.packages(c("caret", "class", "MASS", "e1071"))

# Para importar archivos Excel
install.packages("readxl")
```

```
# Verificar la instalación cargando el paquete
library(tidyverse)
```

4. EL ENTORNO RSTUDIO: PARTES Y FUNCIONES

RStudio está organizado en cuatro paneles principales que se pueden redimensionar y reorganizar según las preferencias del usuario. Conocer cada panel y su función es fundamental para trabajar eficientemente.

Tabla 4. Paneles de RStudio y sus funciones

Panel	Función principal	Tips de uso
Editor de scripts (superior izq.)	Escribir, guardar y ejecutar código R. Permite trabajar con múltiples scripts.	Ctrl+Enter para ejecutar línea actual. Ctrl+Shift+Enter para ejecutar todo.
Consola (inferior izq.)	Ejecutar comandos de forma interactiva. Muestra resultados y mensajes de error.	Usar ↑ para recuperar comandos anteriores.
Environment / History (superior der.)	Environment: muestra los objetos cargados en memoria. History: historial de comandos.	Revisar los objetos creados durante la sesión.
Files / Plots / Packages / Help (inferior der.)	Files: explorador de archivos. Plots: gráficos generados. Help: documentación de funciones.	Para ver ayuda de una función: ?nombre_funcion

4.1 Proyectos en RStudio

Se recomienda trabajar siempre dentro de un Proyecto de RStudio (.Rproj). Un proyecto organiza todos los archivos relacionados (datos, scripts, resultados) en una carpeta y configura el directorio de trabajo automáticamente.

1. Crear: File → New Project → New Directory.
2. Asignar un nombre descriptivo al proyecto (ej. BigData_Unidad1).
3. El archivo .Rproj se crea en la carpeta raíz del proyecto.
4. Al abrir el .Rproj, RStudio carga el entorno de trabajo completo.

[R]

```
# Ver el directorio de trabajo actual
getwd()

# Listar archivos en la carpeta de trabajo
list.files()
```

5. OPERACIONES BÁSICAS EN R

5.1 Tipos de datos y objetos básicos

En R, todo es un objeto. Los tipos de datos más comunes son:

Tabla 5. Tipos de datos fundamentales en R

Tipo	Descripción	Ejemplo de creación	Verificación
numeric	Números reales	x <- 3.14	class(x) # 'numeric'
integer	Números enteros	n <- 5L	class(n) # 'integer'
character	Texto (cadenas)	nombre <- 'Ana'	class(nombre) # 'character'
logical	Valores booleanos	flag <- TRUE	class(flag) # 'logical'
factor	Variables categóricas	f <- factor('A','B')	levels(f)
Date	Fechas	hoy <- Sys.Date()	class(hoy) # 'Date'

5.2 Vectores

El vector es la estructura de datos fundamental en R:

[R]

```
# Crear vectores
edades <- c(22, 25, 19, 30, 28)
nombres <- c('Ana', 'Luis', 'María', 'José', 'Clara')
activos <- c(TRUE, TRUE, FALSE, TRUE, FALSE)

# Operaciones vectorizadas (se aplican a todos los elementos)
edades + 1      # suma 1 a cada elemento
edades > 25     # devuelve TRUE/FALSE por elemento
mean(edades)   # promedio
sd(edades)     # desviación estándar

# Acceder a elementos por índice (R es 1-indexado)
edades[1]      # primer elemento: 22
edades[c(1, 3)] # elementos 1 y 3
edades[edades > 24] # filtrado lógico
```

5.3 Data Frames

El data frame es la estructura más usada en análisis de datos. Es equivalente a una tabla con filas (observaciones) y columnas (variables):

[R]

```
# Crear un data frame
estudiantes <- data.frame(
  nombre = c('Ana', 'Luis', 'María', 'José'),
  edad   = c(22, 25, 19, 30),
  nota   = c(8.5, 7.0, 9.2, 6.8),
  activo = c(TRUE, TRUE, TRUE, FALSE)
)

# Exploración básica
nrow(estudiantes) # número de filas
ncol(estudiantes) # número de columnas
colnames(estudiantes) # nombres de columnas
str(estudiantes)   # estructura completa

# Acceder a columnas
estudiantes$nombre # por nombre con $
estudiantes[, 'nota'] # por nombre con []
estudiantes[1, ]    # primera fila
```

```
# Filtrar filas
estudiantes[estudiantes$nota > 7.5, ]
```

6. IMPORTACIÓN Y EXPLORACIÓN INICIAL DE DATOS

6.1 Lectura de archivos

R ofrece múltiples funciones para importar datos de diferentes fuentes. Los formatos más comunes en análisis de Big Data son CSV y Excel:

[R]

```
# --- Leer archivos CSV ---
# Con R base
datos <- read.csv('datos.csv', header = TRUE, sep = ',')

# Con readr (tidyverse) – más rápido para archivos grandes
library(readr)
datos <- read_csv('datos.csv')

# --- Leer archivos Excel (.xlsx) ---
library(readxl)
datos <- read_excel('libro.xlsx', sheet = 1)

# --- Leer desde URL (datos públicos) ---
url <- 'https://raw.githubusercontent.com/.../datos.csv'
datos <- read_csv(url)
```

6.2 Inspección inicial del dataset

Antes de realizar cualquier análisis es imprescindible explorar el dataset. Las siguientes funciones son esenciales:

[R]

```
# Dimensiones
dim(datos)           # filas y columnas
nrow(datos); ncol(datos)

# Vista rápida
head(datos, 10)      # primeras 10 filas
tail(datos, 5)       # últimas 5 filas

# Estructura y tipos
str(datos)           # tipos de cada columna
glimpse(datos)       # versión tidyverse de str()

# Resumen estadístico
summary(datos)

# Valores perdidos
is.na(datos)         # TRUE donde hay NA
colSums(is.na(datos)) # conteo de NAs por columna
sum(is.na(datos))    # total de NAs
```




```
# Valores únicos y frecuencias
unique(datos$categoria)
table(datos$categoria)
```

6.3 Limpieza básica de datos

Las tareas más comunes de limpieza en R con dplyr:

[R]

```
library(dplyr)

datos_limpios <- datos |>
  # Eliminar filas con cualquier NA
  na.omit() |>
  # Renombrar columnas
  rename(id = ID, valor = Value) |>
  # Filtrar registros
  filter(valor > 0) |>
  # Seleccionar columnas
  select(id, valor, categoria) |>
  # Crear nueva columna
  mutate(log_valor = log(valor))
```

7. VISUALIZACIÓN CON R BASE Y GGPLOT2

7.1 Gráficos con R base

R incluye funciones de visualización sin necesidad de librerías adicionales. Son rápidas y útiles para una exploración inicial:

[R]

```
# Histograma
hist(datos$valor,
      main = 'Distribución de valores',
      xlab = 'Valor', col = 'steelblue', border = 'white')

# Gráfico de caja (boxplot)
boxplot(valor ~ categoria, data = datos,
        main = 'Valor por categoría',
        col = c('#2ECC71', '#3498DB', '#E74C3C'))

# Diagrama de dispersión
plot(datos$variable_x, datos$variable_y,
      main = 'Dispersión', xlab = 'X', ylab = 'Y',
      pch = 19, col = 'navy', cex = 0.8)

# Añadir línea de regresión
abline(lm(variable_y ~ variable_x, data = datos),
      col = 'red', lwd = 2)
```



7.2 Visualización con ggplot2

ggplot2 es la librería de visualización más potente y popular de R. Se basa en la Gramática de Gráficos (Grammar of Graphics): un gráfico se construye capas (layers) especificando datos, estética (aes) y geometrías (geom_*):

[R]

```
library(ggplot2)

# Estructura base de ggplot2
# ggplot(datos, aes(x = var_x, y = var_y, color = grupo)) +
#   geom_*() + labs() + theme_*()

# Histograma
ggplot(datos, aes(x = valor)) +
  geom_histogram(fill = '#2980B9', color = 'white', bins = 30) +
  labs(title = 'Distribución de valores',
        x = 'Valor', y = 'Frecuencia') +
  theme_minimal()

# Dispersión con grupos
ggplot(datos, aes(x = var_x, y = var_y, color = categoria)) +
  geom_point(alpha = 0.7, size = 2) +
  geom_smooth(method = 'lm', se = FALSE) +
  labs(title = 'Relación X-Y por categoría') +
  theme_bw() +
  scale_color_manual(values = c('#E74C3C', '#2ECC71', '#3498DB'))

# Boxplot por grupo
ggplot(datos, aes(x = categoria, y = valor, fill = categoria)) +
  geom_boxplot(outlier.color = 'red', outlier.shape = 1) +
  theme_minimal() + theme(legend.position = 'none')
```

Tabla 6. Geometrías principales de ggplot2

Geometría (geom)	Tipo de gráfico	Uso recomendado
geom_point()	Diagrama de dispersión	Relación entre dos variables numéricas
geom_line()	Gráfico de líneas	Series temporales, tendencias
geom_bar()	Barras (frecuencias)	Conteo de categorías
geom_col()	Barras (valores predefinidos)	Valores ya calculados
geom_histogram()	Histograma	Distribución de una variable numérica
geom_boxplot()	Caja y bigotes	Distribución y outliers por grupo
geom_violin()	Gráfico de violín	Distribución de densidad por grupo
geom_density()	Curva de densidad	Estimación de distribución suavizada
geom_heatmap()	Mapa de calor	Matrices de correlación, frecuencia cruzada
facet_wrap()	Facetas por variable	Múltiples gráficos por categoría

8. BUENAS PRÁCTICAS Y REPRODUCIBILIDAD

La reproducibilidad es uno de los principios fundamentales de la ciencia de datos. Un análisis es reproducible cuando cualquier persona puede seguir los mismos pasos y obtener exactamente los mismos resultados. En Big Data esto es especialmente importante dado el volumen y complejidad de los datos involucrados.

8.1 Organización del proyecto

Estructura recomendada de carpetas para proyectos de datos:

[Estructura de directorios]

```
BigData_Unidad1/
├── data/
│   ├── raw/           # datos originales (NUNCA se modifican)
│   ├── processed/     # datos limpios y transformados
│   └── external/      # datos de fuentes externas
├── scripts/
│   ├── 01_carga.R
│   ├── 02_limpieza.R
│   ├── 03_exploracion.R
│   └── 04_modelado.R
├── output/
│   ├── figures/       # gráficos exportados
│   └── tables/        # tablas exportadas
├── reports/          # informes finales
└── BigData_Unidad1.Rproj
```

8.2 Comentarios y documentación en R

[R]

```
# =====
# Script: 01_carga_exploracion.R
# Autor:  Nombre del estudiante
# Fecha:  2026-03-05
# Desc:   Carga y exploración inicial del dataset
# =====

# --- 1. Librerías ----
library(tidyverse)
library(readxl)

# --- 2. Carga de datos ----
# Ruta relativa al proyecto (no absolutas: evita problemas entre computadoras)
datos <- read_csv('data/raw/dataset.csv')

# --- 3. Exploración ----
glimpse(datos) # verificar estructura
summary(datos) # resumen estadístico
```

 Regla de oro: nunca modificar los datos originales (`raw/`). Toda transformación debe hacerse en el script y guardarse en `processed/`. Esto garantiza que siempre se pueda volver al punto de partida.



- Usar nombres descriptivos: mejor analisis_ventas_2026.R que script_final_v3.R
- Numerar scripts en orden de ejecución: 01_, 02_, 03_...
- Usar rutas relativas (no absolutas): data/raw/datos.csv no C:/Usuario/...
- Fijar la semilla aleatoria para resultados reproducibles: set.seed(42)
- Documentar la versión de R y paquetes: sessionInfo()

9. REFERENCIAS Y RECURSOS

9.1 Bibliografía básica

- Wickham, H. y Grolemund, G. (2023). R for Data Science (2ª ed.). O'Reilly. Disponible en: <https://r4ds.hadley.nz/>
- James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). An Introduction to Statistical Learning with Applications in R (2ª ed.). Springer. Disponible en: <https://www.statlearning.com/>
- Silge, J. y Robinson, D. (2017). Text Mining with R. O'Reilly. Disponible en: <https://www.tidytextmining.com/>
- Irizarry, R. A. (2022). Introduction to Data Science. Disponible en: <https://rafalab.github.io/dsbook/>

9.2 Complementarias y recursos en línea

- Kabacoff, R. I. (2015). R in Action (2ª ed.). Manning Publications.
- Grolemund, G. (2014). Hands-On Programming with R. O'Reilly.
- CRAN Task Views — Big Data: <https://cran.r-project.org/view=BigData>
- Posit Cloud (antes RStudio.cloud): plataforma gratuita para usar R en el navegador.
- RStudio Community: <https://community.rstudio.com/>
- Stack Overflow (etiqueta [r]): <https://stackoverflow.com/questions/tagged/r>
- Swirl — aprende R desde la consola: `install.packages('swirl');` `library(swirl)`

 Recomendación del docente: comenzar con el Capítulo 1 de 'R for Data Science' (Wickham & Grolemund) y complementar con los tutoriales de Swirl para practicar los conceptos básicos de R de forma interactiva.