

Material de Lectura Extendido

Unidad 2: Visualización y exploración de datos

Departamento de Educación a Distancia

Analítica de Big Data

Material de Lectura - Unidad 2: Visualización y Exploración de Datos en Big Data

Año 2025

Unidad 2: Visualización y Exploración de Datos en Big Data

La visualización y exploración de datos (Análisis Exploratorio de Datos, EDA) es un pilar en proyectos de Big Data. Esta unidad cubre tipos de variables, distribuciones, técnicas de preprocesado e imputación de missing values, con ejemplos prácticos en Python y R, tablas resumidas, diagramas y visualizaciones para un aprendizaje interactivo y profundo.

4.2.1 Tipos de Variables y Distribución

Identificar tipos de variables es esencial para elegir técnicas adecuadas en Big Data. Los tipos principales incluyen cuantitativas (discretas o continuas) y cualitativas (nominales u ordinales). Las distribuciones (normal, sesgada) guían transformaciones como log o Box-Cox.

Tabla 1: Tipos de Variables en Datos

Tipo	Subtipo	Descripción	Ejemplo
Cuantitativa	Discreta	Valores contables enteros.	Número de clientes (10, 20, 30).
Cuantitativa	Continua	Valores en un rango continuo.	Peso (65.5 kg), tiempo (3.2 horas).
Cualitativa	Nominal	Categorías sin orden.	Color (rojo, azul), género.
Cualitativa	Ordinal	Categorías con orden.	Nivel educativo (básico, medio, superior).

Fuente: Elaboración propia basada en Tukey (1977).

Figura 1: Diagrama de Tipos de Variables

Fuente: Stats and R - Variable types and examples.

4.2.2 Exploración de Datos (EDA)

EDA revela estructura y patrones en datos antes de modelado. Incluye estadísticas descriptivas y visualizaciones uni/multivariadas.

Tabla 2: Técnicas Comunes en EDA

Técnica	Propósito	Herramienta	Ejemplo
Estadísticas Descriptivas	Resumir datos (media, mediana).	pandas.describe() / R summary().	
Histogramas	Visualizar distribución univariada.	seaborn.histplot() / ggplot geom_histogram().	
Boxplots	Detectar outliers y dispersión.	seaborn.boxplot() / ggplot geom_boxplot().	
Scatter Plots	Explorar relaciones bivariadas.	matplotlib.scatter() / ggplot geom_point().	
Heatmaps	Visualizar correlaciones.	seaborn.heatmap() / GGally ggcorr().	

Fuente: Adaptado de Wickham (2016).

Ejemplo en Python: Exploración Básica con Pandas y Seaborn

Este script carga datos, computa estadísticas y visualiza distribución y correlaciones.

Python Code:

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Cargar dataset
df = pd.read_csv('clientes_compras.csv')

# Primeras filas
print(df.head())

# Estadísticas descriptivas
print(df.describe())

# Histograma de 'edad'
sns.histplot(data=df, x='edad', kde=True)
plt.title('Distribución de Edad de Clientes')
plt.show()

# Heatmap de correlaciones
corr = df.corr()
```

```
df.corr().sns.heatmap(corr, annot=True, cmap='coolwarm')plt.title('Mapa de Calor de Correlaciones')plt.show()
```

Figura 2: Ejemplo de Histograma

Fuente: Atlassian - Histograms Unveiled.

Figura 3: Ejemplo de Heatmap de Correlaciones

Fuente: Indianaiproduction - Seaborn Heatmap.

Ejemplo en R: Exploración con ggplot2 y GGally

Script equivalente en R para resumen y visualizaciones.

R Code:

```
library(ggplot2)library(GGally)# Cargar datasetdf <- read.csv('clientes_compras.csv')# Primeras filashead(df)# Resumen estadísticosummary(df)# Histograma de edadggplot(df, aes(x=edad)) + geom_histogram(binwidth=5, fill='blue', color='white') + labs(title='Distribución de Edad de Clientes', x='Edad', y='Frecuencia')# Correlacionesggcorr(df, label=TRUE)
```

4.2.3 Preprocesado de los Datos

Preprocesado limpia y transforma datos para modelado. Etapas clave incluyen limpieza, transformación y selección de features.

Tabla 3: Etapas de Preprocesado

Etapas	Descripción	Técnica	Ejemplo
Limpieza	Eliminar duplicados/outliers.	Drop duplicates en pandas / unique() en R.	
Transformación	Normalizar/escalar variables.	sklearn.StandardScaler / scale() en R.	
Selección	Reducir dimensionalidad.	PCA en sklearn / prcomp() en R.	

Fuente: Adaptado de McKinney (2017).

Figura 4: Boxplot para Detección de Outliers

Fuente: ChartExpo - Box Plot Outliers.

4.2.4 Imputación de Valores Ausentes

Manejar missing values evita sesgos. Estrategias: eliminación, imputación estadística o modelada.

Tabla 4: Estrategias de Imputación

Estrategia	Ventajas	Desventajas	Uso Típico
Eliminación	Simple, no introduce sesgos.	Pérdida de datos.	Baja proporción de missing.
Media/Mediana	Rápida, mantiene distribución.	Puede sesgar varianza.	Variables numéricas.
Moda	Útil para categóricas.	Ignora relaciones.	Variables cualitativas.
KNN/Regresión	Considera similitudes.	Computacionalmente intensivo.	Datasets complejos.

Fuente: Adaptado de VanderPlas (2016).

Ejemplo en Python: Imputación con Pandas y Scikit-learn

Ejemplo manejando missing values: eliminación e imputación con media, mediana y KNN.

Python Code:

```
import pandas as pdfrom sklearn.impute import KNNImputer# Cargar datasetdf = pd.read_csv('datos_incompletos.csv')# Eliminacióndf_drop = df.dropna()# Imputación media/medianadf_fill_mean = df.fillna(df.mean(numeric_only=True))df_fill_median = df.fillna(df.median(numeric_only=True))# Imputación KNNimputer = KNNImputer(n_neighbors=5)df_knn = pd.DataFrame(imputer.fit_transform(df), columns=df.columns)# Verificar missing restantesprint(df_knn.isna().sum())
```

Ejemplo en R: Imputación con Base R y mice

Imputación básica y avanzada con paquete mice.

R Code:

```
library(mice)# Cargar datasetdf <- read.csv('datos_incompletos.csv')# Eliminacióndf_drop <-  
na.omit(df)# Imputación mediadf$col_numerica[is.na(df$col_numerica)] <- mean(df$col_numerica, na.rm =  
TRUE)# Imputación múltiple con miceimp <- mice(df, m=5, maxit=50, method='pmm', seed=500)df_complete  
<- complete(imp, 1)# Verificarsum(is.na(df_complete))
```

Conclusiones de la Unidad 2

EDA y preprocesado aseguran datos de calidad para Big Data analytics. Con herramientas como Python/Seaborn y R/ggplot2, analistas detectan insights tempranos, reduciendo errores en modelado. Futuras tendencias incluyen EDA automatizada con IA.

Bibliografía

- Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.
- Cleveland, W. S. (1993). Visualizing Data. Hobart Press.
- Wickham, H. (2016). ggplot2: Elegant Graphics for Data Analysis. Springer.
- McKinney, W. (2017). Python for Data Analysis. O'Reilly Media.
- VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly Media.
- Additional: Seaborn Documentation. <https://seaborn.pydata.org/>
- ggplot2 Official. <https://ggplot2.tidyverse.org/>