

Material de Lectura Extendido

Unidad 2: Visualización y exploración de datos

Departamento de Educación a Distancia

Analítica de Big Data

Material de Lectura - Unidad 2: Visualización y Exploración de Datos en Big Data

Año 2025

Unidad 2: Visualización y Exploración de Datos en Big Data

La visualización y exploración de datos (Análisis Exploratorio de Datos, EDA) es un pilar en proyectos de Big Data. Esta unidad cubre tipos de variables, distribuciones, técnicas de preprocesado e imputación de missing values, con ejemplos prácticos en Python y R, tablas resumidas, diagramas y visualizaciones para un aprendizaje interactivo y profundo.

4.2.1 Tipos de Variables y Distribución

Identificar tipos de variables es esencial para elegir técnicas adecuadas en Big Data. Los tipos principales incluyen cuantitativas (discretas o continuas) y cualitativas (nominales u ordinales). Las distribuciones (normal, sesgada) guían transformaciones como log o Box-Cox.

Tabla 1: Tipos de Variables en Datos

Tipo | Subtipo | Descripción | Ejemplo

Cuantitativa | Discreta | Valores contables enteros. | Número de clientes (10, 20, 30).

Cuantitativa | Continua | Valores en un rango continuo. | Peso (65.5 kg), tiempo (3.2 horas).

Cualitativa | Nominal | Categorías sin orden. | Color (rojo, azul), género.

Cualitativa | Ordinal | Categorías con orden. | Nivel educativo (básico, medio, superior).

Fuente: Elaboración propia basada en Tukey (1977).

Figura 1: Diagrama de Tipos de Variables

Fuente: Stats and R - Variable types and examples.

4.2.2 Exploración de Datos (EDA)

EDA revela estructura y patrones en datos antes de modelado. Incluye estadísticas descriptivas y visualizaciones uni/multivariadas.

Tabla 2: Técnicas Comunes en EDA

Técnica | Propósito | Herramienta Ejemplo

Estadísticas Descriptivas | Resumir datos (media, mediana). | pandas.describe() / R summary().

Histogramas | Visualizar distribución univariada. | seaborn.histplot() / ggplot geom_histogram().

Boxplots | Detectar outliers y dispersión. | seaborn.boxplot() / ggplot geom_boxplot().

Scatter Plots | Explorar relaciones bivariadas. | matplotlib.scatter() / ggplot geom_point().

Heatmaps | Visualizar correlaciones. | seaborn.heatmap() / GGally ggcorr().

Fuente: Adaptado de Wickham (2016).

Ejemplo en Python: Exploración Básica con Pandas y Seaborn

Este script carga datos, computa estadísticas y visualiza distribución y correlaciones.

Python Code:

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Cargar dataset
df = pd.read_csv('clientes_compras.csv')

# Primeras filas
print(df.head())

# Estadísticas descriptivas
print(df.describe())

# Histograma
```

```
de 'edad'sns.histplot(data=df, x='edad', kde=True)plt.title('Distribución de Edad de Clientes')plt.show()# Heatmap de correlacionescorr = df.corr()sns.heatmap(corr, annot=True, cmap='coolwarm')plt.title('Mapa de Calor de Correlaciones')plt.show()
```

Figura 2: Ejemplo de Histograma

Fuente: Atlassian - Histograms Unveiled.

Figura 3: Ejemplo de Heatmap de Correlaciones

Fuente: Indianaiproduction - Seaborn Heatmap.

Ejemplo en R: Exploración con ggplot2 y GGally

Script equivalente en R para resumen y visualizaciones.

R Code:

```
library(ggplot2)library(GGally)# Cargar datasetdf <- read.csv('clientes_compras.csv')# Primeras filashead(df)# Resumen estadísticossummary(df)# Histograma de edadggplot(df, aes(x=edad)) + geom_histogram(binwidth=5, fill='blue', color='white') + labs(title='Distribución de Edad de Clientes', x='Edad', y='Frecuencia')# Correlacionesggcorr(df, label=TRUE)
```

4.2.3 Preprocesado de los Datos

Preprocesado limpia y transforma datos para modelado. Etapas clave incluyen limpieza, transformación y selección de features.

Tabla 3: Etapas de Preprocesado

Etapas | Descripción | Técnica Ejemplo

Limpieza | Eliminar duplicados/outliers. | Drop duplicates en pandas / unique() en R.

Transformación | Normalizar/escalar variables. | sklearn.StandardScaler / scale() en R.

Selección | Reducir dimensionalidad. | PCA en sklearn / prcomp() en R.

Fuente: Adaptado de McKinney (2017).

Figura 4: Boxplot para Detección de Outliers

Fuente: ChartExpo - Box Plot Outliers.

4.2.4 Imputación de Valores Ausentes

Manejar missing values evita sesgos. Estrategias: eliminación, imputación estadística o modelada.

Tabla 4: Estrategias de Imputación

Estrategia | Ventajas | Desventajas | Uso Típico

Eliminación | Simple, no introduce sesgos. | Pérdida de datos. | Baja proporción de missing.

Media/Mediana | Rápida, mantiene distribución. | Puede sesgar varianza. | Variables numéricas.

Moda | Útil para categóricas. | Ignora relaciones. | Variables cualitativas.

KNN/Regresión | Considera similitudes. | Computacionalmente intensivo. | Datasets complejos.

Fuente: Adaptado de VanderPlas (2016).

Ejemplo en Python: Imputación con Pandas y Scikit-learn

Ejemplo manejando missing values: eliminación e imputación con media, mediana y KNN.

Python Code:

```
import pandas as pdfrom sklearn.impute import KNNImputer# Cargar datasetdf = pd.read_csv('datos_incompletos.csv')# Eliminacióndf_drop = df.dropna()# Imputación media/medianadf_fill_mean = df.fillna(df.mean(numeric_only=True))df_fill_median = df.fillna(df.median(numeric_only=True))# Imputación KNNImputer = KNNImputer(n_neighbors=5)df_knn = pd.DataFrame(imputer.fit_transform(df), columns=df.columns)# Verificar missing restantesprint(df_knn.isna().sum())
```

Ejemplo en R: Imputación con Base R y mice

Imputación básica y avanzada con paquete mice.



R Code:

```
library(mice)# Cargar datasetdf <- read.csv('datos_incompletos.csv')# Eliminacióndf_drop <- na.omit(df)# Imputación  
mediadf$col_numerica[is.na(df$col_numerica)] <- mean(df$col_numerica, na.rm = TRUE)# Imputación múltiple con miceimp <-  
mice(df, m=5, maxit=50, method='pmm', seed=500)df_complete <- complete(imp, 1)# Verificarsum(is.na(df_complete))
```

Conclusiones de la Unidad 2

EDA y preprocesado aseguran datos de calidad para Big Data analytics. Con herramientas como Python/Seaborn y R/ggplot2, analistas detectan insights tempranos, reduciendo errores en modelado. Futuras tendencias incluyen EDA automatizada con IA.

Bibliografía

- Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.
- Cleveland, W. S. (1993). Visualizing Data. Hobart Press.
- Wickham, H. (2016). ggplot2: Elegant Graphics for Data Analysis. Springer.
- McKinney, W. (2017). Python for Data Analysis. O'Reilly Media.
- VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly Media.
- Additional: Seaborn Documentation. <https://seaborn.pydata.org/>
- ggplot2 Official. <https://ggplot2.tidyverse.org/>

