

Material de Lectura Extendido

Unidad 3: Machine Learning

Departamento de Educación a Distancia

Analítica de Big Data

Material de Lectura - Unidad 3: Machine Learning en Big Data con R

Año 2025

Unidad 3: Machine Learning en Big Data con R

El Machine Learning (ML) es esencial para extraer insights de grandes volúmenes de datos en Big Data. Esta unidad introduce conceptos clave de ML, enfocándose en modelos predictivos como K-Nearest Neighbors (KNN), Naive Bayes y Regresión Logística. Exploraremos explicaciones teóricas, ventajas/desventajas, ejemplos en R, diagramas y aplicaciones reales para un aprendizaje completo y práctico.

3.1 Introducción al Machine Learning en Big Data

ML permite a las máquinas aprender patrones de datos sin programación explícita. En Big Data, maneja volúmenes masivos con algoritmos escalables. Tipos: Supervisado (etiquetado), No Supervisado (patrones), Reforzamiento (recompensas). Enfoque en supervisado para clasificación/regresión.

Tabla 1: Tipos de Machine Learning

Tipo	Descripción	Ejemplos	Uso en Big Data
Supervisado	Aprende de datos etiquetados para predecir.	Clasificación, Regresión.	Predicción de churn en telecomunicaciones.
No Supervisado	Encuentra patrones sin etiquetas.	Clustering, Reducción dimensional.	Segmentación de clientes en e-commerce.
Reforzamiento	Aprende por ensayo-error con recompensas.	Q-Learning, Deep RL.	Optimización de rutas en logística.
Semi-Supervisado	Mezcla etiquetados y no etiquetados.	Autoencoders.	Clasificación de imágenes con datos limitados.

Fuente: Adaptado de GeeksforGeeks y DataCamp tutorials.

Error al insertar figura: 403 Client Error: Forbidden for url:

<https://www.researchgate.net/publication/342062164/figure/fig1/AS:900227347886082@1592604879453/Machine-Learning>

3.2 Creación de Modelos Predictivos

En ML supervisado, se divide datos en entrenamiento/test, se entrena el modelo y se evalúa (accuracy, precision, recall, F1-score). En R, paquetes como caret facilitan este flujo.

Ejemplo en R: Flujo Básico de ML con caret

R Code:

```
library(caret)# Cargar datos (ej. iris)data(iris)# Dividir en train/testset.seed(123)trainIndex <-  
createDataPartition(iris$Species, p=0.8, list=FALSE)train <- iris[trainIndex,]test <-  
iris[-trainIndex,]# Entrenar modelo (ej. KNN)model <- train(Species ~ ., data=train, method="knn")#  
Predecir y evaluarpredictions <- predict(model, test)confusionMatrix(predictions, test$Species)
```

Este ejemplo usa caret para partición, entrenamiento y evaluación, común en Big Data para escalabilidad.

3.3 K-Nearest Neighbors (KNN)

KNN es un algoritmo no paramétrico de aprendizaje basado en instancias. Clasifica un punto nuevo basado en la mayoría de votos de sus K vecinos más cercanos, usando distancias como Euclídea. Ideal

para datasets pequeños a medianos; en Big Data, usar aproximaciones como KD-trees.

Fórmula de Distancia Euclídea: $d(p, q) = \sqrt{\sum (p_i - q_i)^2}$

Tabla 2: Ventajas y Desventajas de KNN

Aspecto | Ventajas | Desventajas

Simplicidad | Fácil de entender e implementar. | Sensible a ruido y outliers.

No paramétrico | No asume distribución de datos. | Alto costo computacional en predicción.

Flexibilidad | Bueno para clasificación multi-clase. | Requiere elección óptima de K.

Escalabilidad | Útil en datasets no lineales. | No escala bien con Big Data sin optimizaciones.

Fuente: Adaptado de DataCamp KNN Tutorial.

Ejemplo en R: Implementación de KNN con class

R Code:

```
library(class)library(caret)# Datos irisdata(iris)# Normalizar (opcional)normalize <- function(x) {  
  return ((x - min(x)) / (max(x) - min(x))) }iris_norm <- as.data.frame(lapply(iris[1:4], normalize))#  
Train/test splitset.seed(123)trainIndex <- createDataPartition(iris$Species, p=0.8,  
list=FALSE)train_data <- iris_norm[trainIndex,]train_labels <- iris$Species[trainIndex]test_data <-  
iris_norm[-trainIndex,]test_labels <- iris$Species[-trainIndex]# KNN con K=3predictions <-  
knn(train=train_data, test=test_data, cl=train_labels, k=3)# EvaluaciónconfusionMatrix(predictions,  
test_labels)
```

Este código normaliza features, aplica KNN y evalúa con matriz de confusión.

Figura 2: Diagrama de KNN

Fuente: GeeksforGeeks - KNN Algorithm.

3.4 Naive Bayes

Naive Bayes es un clasificador probabilístico basado en el Teorema de Bayes, asumiendo independencia entre features (naive). Eficiente para texto y Big Data, variantes: Gaussian (continuas), Multinomial (discretas), Bernoulli (binarias).

Teorema de Bayes: $P(C|X) = \frac{P(X|C) P(C)}{P(X)}$

Tabla 3: Ventajas y Desventajas de Naive Bayes

Aspecto | Ventajas | Desventajas

Eficiencia | Rápido en entrenamiento y predicción. | Asume independencia (puede no ser real).

Manejo de datos | Bueno con datos categóricos y texto. | Problemas con zero-frequency (Laplace smoothing).

Escalabilidad | Escala bien con Big Data. | Menos preciso en datasets complejos.

Simplicidad | Fácil interpretación probabilística. | No maneja bien interacciones entre features.

Fuente: Adaptado de Edureka Naive Bayes Tutorial.

Ejemplo en R: Naive Bayes con e1071

R Code:

```
library(e1071)library(caret)# Datos iris (para clasificación)data(iris)# Train/test  
splitset.seed(123)trainIndex <- createDataPartition(iris$Species, p=0.8, list=FALSE)train <-  
iris[trainIndex,]test <- iris[-trainIndex,]# Entrenar Naive Bayesmodel <- naiveBayes(Species ~ .,  
data=train)# Predecirpredictions <- predict(model, test[,1:4])#  
EvaluaciónconfusionMatrix(predictions, test$Species)
```

Ejemplo simple con iris; en Big Data, útil para spam filtering o sentiment analysis.

Figura 3: Diagrama de Naive Bayes

Fuente: Medium - Mastering Naive Bayes.

3.5 Regresión Logística

Regresión Logística modela probabilidades para clasificación binaria/multinomial usando función sigmoide. Extiende regresión lineal para outputs categóricos.

Función Logística: $p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$

Tabla 4: Ventajas y Desventajas de Regresión Logística

Aspecto | Ventajas | Desventajas

Interpretabilidad | Coeficientes fáciles de interpretar. | Asume linealidad en logit.

Eficiencia | Rápida, no requiere mucho cómputo. | Sensible a multicolinealidad.

Probabilidades | Output probabilístico directo. | No maneja bien no-linealidades complejas.

Escalabilidad | Buena para Big Data con regularización. | Requiere datos balanceados.

Fuente: Adaptado de Statology Logistic Regression Tutorial.

Ejemplo en R: Regresión Logística Binaria con glm

R Code:

```
# Datos de ejemplo (titanic simplificado) data <- read.csv('titanic.csv') # Asumir columnas: Survived,
Pclass, Sex, Age, etc. # Convertir factores data$Survived <- factor(data$Survived) data$Sex <-
factor(data$Sex) # Train/test split set.seed(123) trainIndex <- createDataPartition(data$Survived,
p=0.8, list=FALSE) train <- data[trainIndex,] test <- data[-trainIndex,] # Modelo logit model <-
glm(Survived ~ Pclass + Sex + Age, data=train, family="binomial") # Predecir
probabilidades probabilities <- predict(model, test, type="response") predictions <-
ifelse(probabilities > 0.5, 1, 0) # Evaluación confusionMatrix(factor(predictions), test$Survived)

Usando glm para clasificación binaria; en Big Data, aplicar en churn prediction o fraud detection.
```

Figura 4: Frontera de Decisión en Regresión Logística

Fuente: Medium - Logistic Regression and Decision Boundary.

3.6 Comparación de Algoritmos

Selección depende de datos: KNN para no-lineales, Naive Bayes para texto, Logística para interpretabilidad.

Tabla 5: Comparación de Algoritmos

Algoritmo | Tipo | Fortalezas | Debilidades | Uso en Big Data

KNN | Basado en instancias | Simple, no asume distribución. | Lento en predicción. | Clasificación local con aproximaciones.

Naive Bayes | Probabilístico | Rápido, maneja alta dimensionalidad. | Asume independencia. | Análisis de texto/spam en streams.

Regresión Logística | Lineal | Interpretabilidad, probabilidades. | Lineal en logit. | Predicciones binarias escalables.

Fuente: Elaboración propia basada en tutorials de DataCamp y GeeksforGeeks.

3.7 Aplicaciones Reales en Big Data

ML en Big Data: Recomendadores (Netflix - KNN), detección spam (Gmail - Naive Bayes), riesgo crediticio (bancos - Logística).

Tabla 6: Aplicaciones Reales

Algoritmo | Aplicación | Ejemplo | Beneficio

KNN | Sistemas de recomendación. | Spotify playlists. | Personalización basada en similitud.

Naive Bayes | Clasificación de texto. | Filtro spam en email. | Procesamiento rápido de volúmenes masivos.

Regresión Logística | Predicción binaria. | Churn en telecom. | Evaluación de probabilidades de

retención.

Fuente: Adaptado de R-bloggers y Analytics Vidhya.

Conclusiones de la Unidad 3

ML transforma Big Data en insights accionables. KNN, Naive Bayes y Regresión Logística son bases sólidas; en R, paquetes como caret/e1071 facilitan implementación. Futuro: Integración con Spark para escalabilidad extrema.

Bibliografía

- DataCamp. (2023). K-Nearest Neighbors (KNN) Classification with R Tutorial.
<https://www.datacamp.com/tutorial/k-nearest-neighbors-knn-classification-with-r-tutorial>
- Edureka. (2019). A Step By Step Guide To Implement Naive Bayes In R.
<https://medium.com/edureka/naive-bayes-in-r-37ca73f3e85c>
- Statology. How to Perform Logistic Regression in R (Step-by-Step).
<https://www.statology.org/logistic-regression-in-r/>
- GeeksforGeeks. (2025). Introduction to Machine Learning in R.
<https://www.geeksforgeeks.org/r-machine-learning/introduction-to-machine-learning-in-r/>
- Additional: R-bloggers. (2021). Naive Bayes Classification in R.
<https://www.r-bloggers.com/2021/04/naive-bayes-classification-in-r/>
- Wickham, H. (2016). ggplot2: Elegant Graphics for Data Analysis. Springer.
- Lutz, M. (2013). Learning Python. O'Reilly Media (for general ML context).