

Material de Lectura Extendido

Unidad 4: Interpretación de resultados y modelos estadísticos

Departamento de Educación a Distancia

Analítica de Big Data

Material de Lectura - Unidad 4: Interpretación de Resultados y Modelos Estadísticos en Big Data

Año 2025

Unidad 4: Interpretación de Resultados y Modelos Estadísticos en Big Data

La interpretación de resultados es crucial para convertir datos en acciones. Esta unidad cubre análisis discriminante lineal (LDA), interpretación de modelos, selección de resultados y generación de información estadística en Big Data. Incluimos teoría, ventajas, ejemplos en R, tablas comparativas, diagramas y casos reales para un entendimiento profundo.

4.1 Introducción a la Interpretación en Modelos Estadísticos

En Big Data, interpretar modelos implica entender coeficientes, importancia de variables y métricas de performance. Evita 'caja negra' con técnicas explicables; clave para toma de decisiones éticas y accionables.

Tabla 1: Métricas Clave para Interpretación de Modelos

Métrica | Descripción | Uso | Ejemplo en R

Accuracy | Proporción de predicciones correctas. | Clasificación general. | `confusionMatrix()` `accuracy`.

Precision/Recall | Balance falsos positivos/negativos. | Clasificación imbalanceada. | `precision()` / `recall()` en `caret`.

AUC-ROC | Área bajo curva ROC. | Discriminación clases. | `roc()` en `pROC`.

R-squared | Varianza explicada. | Regresión. | `summary(lm_model)$r.squared`.

Feature Importance | Contribución de variables. | Selección modelos. | `varImp()` en `caret`.

Fuente: Adaptado de RDocumentation y Caret package docs.

Error al insertar figura: 404 Client Error: Not Found for url:

https://miro.medium.com/v2/1*9j9ZqNcQzW3GwFQ8b1Wv3Q.png

4.2 Análisis Discriminante Lineal (LDA)

LDA es un método supervisado para clasificación y reducción dimensional. Maximiza separación entre clases minimizando varianza intra-clase. Asume normalidad multivariada y covarianza igual; útil en reconocimiento de patrones.

Función Discriminante:
$$\Delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k$$

Tabla 2: Ventajas y Desventajas de LDA

Aspecto | Ventajas | Desventajas

Eficiencia | Rápido y computacionalmente ligero. | Asume normalidad y homocedasticidad.

Reducción Dimensional | Proyecta datos en espacio de baja dimensión. | Sensible a outliers.

Interpretabilidad | Coeficientes indican importancia de features. | No maneja no-linealidades.

Escalabilidad | Buena para datasets medianos en Big Data. | Requiere matrices invertibles (no colinealidad).

Fuente: Adaptado de Analytics Vidhya LDA Tutorial.

Ejemplo en R: LDA con MASS



R Code:

```
library(MASS)library(caret)# Datos irisdata(iris)# Train/test splitset.seed(123)trainIndex <-
createDataPartition(iris$Species, p=0.8, list=FALSE)train <- iris[trainIndex,]test <- iris[-trainIndex,]# Entrenar LDAmodel <-
lda(Species ~ ., data=train)# Predecirpredicciones <- predict(model, test[,1:4])$class# EvaluaciónconfusionMatrix(predictions,
test$Species)# Visualizar proyeccionesplot(model)
```

Este código entrena LDA en iris, predice y visualiza separaciones.

Error al insertar figura: 406 Client Error: Not Acceptable for url:

https://sebastianraschka.com/images/blog/2014/linear-discriminant-analysis/iris_lda_1.png

4.3 Interpretación y Selección de Resultados

Interpretar implica analizar métricas, visualizaciones y feature importance. Selección: elegir modelo por cross-validation, AIC/BIC o ensemble.

Ejemplo en R: Interpretación con varImp y ROC

R Code:

```
library(caret)library(pROC)# Asumir modelo entrenado (ej. randomForest)model <- train(Species ~ ., data=iris, method="rf")#
Importancia de variablesvarImp(model)# ROC para multiclass (one-vs-all)multi_roc <- multiclass.roc(test$Species,
as.numeric(predictions))print(multi_roc$auc)# Plot ROCplot(multi_roc)
```

Usa varImp para importancia y pROC para curvas ROC en interpretación.

Tabla 3: Criterios para Selección de Modelos

Criterio | Descripción | Fórmula/Ejemplo

Cross-Validation | Evalúa performance en folds. | k-fold CV error.

AIC/BIC | Balancea fit y complejidad. | $AIC = 2k - 2\ln(L)$.

Ensemble Voting | Combina múltiples modelos. | Majority vote.

SHAP Values | Explicabilidad local/global. | SHAP library in R.

Fuente: Adaptado de Hastie et al. (2009) Elements of Statistical Learning.

Error al insertar figura: 404 Client Error: Not Found for url:

<https://christophm.github.io/interpretable-ml-book/images/shap-header.png>

4.4 Generación de Información Estadística en Big Data

Generar info implica reportes, dashboards y narrativas. En R, usa Shiny para interactivos o rmarkdown para informes reproducibles.

Ejemplo en R: Generar Reporte con rmarkdown

R Markdown Code:

```
# En un archivo .Rmd---title: "Reporte Big Data"output: html_document---````{r setup, include=FALSE}knitr::opts_chunk$set(echo
= TRUE)````## Resumen Modelomodel <- lda(Species ~ ., data=iris)summary(model)## Visualizaciónplot(model)````# Renderizar:
rmarkdown::render('report.Rmd')
```

Crea reportes reproducibles integrando código, resultados y narrativas.

4.5 Comparación y Selección de Modelos en Big Data

Compara por métricas, complejidad y escalabilidad. En Big Data, prioriza paralelizables como LDA sobre computacionalmente intensivos.

Tabla 4: Comparación de Modelos para Clasificación

Modelo | Asunciones | Fortalezas | Debilidades | Escalabilidad en Big Data

LDA | Normalidad, covarianza igual. | Reducción dimensional, interpretable. | Sensible a violaciones. | Buena con paralelización.

QDA | Normalidad, covarianza diferente. | Más flexible que LDA. | Sobrefit en alta dimensión. | Moderada.

Logistic Regression | Linealidad en logit. | Probabilidades, regularización. | No captura no-linealidades. | Alta con Spark

ML.

SVM | Margen máximo. | Efectivo en alta dimensión. | Lento en entrenamiento. | Buena con kernels aproximados.

Fuente: Adaptado de Elements of Statistical Learning.

4.6 Aplicaciones Reales en Big Data

LDA en reconocimiento facial (Eigenfaces), interpretación en finanzas para riesgo, selección en bioinformática para genes.

Tabla 5: Aplicaciones Reales de Modelos en Big Data

Modelo	Aplicación	Ejemplo	Beneficio
LDA	Clasificación de documentos.	Topic modeling en noticias.	Reducción dimensional para escalabilidad.
	Interpretación	Análisis de sentiment.	Twitter data insights.
			Explicabilidad para decisiones de marketing.
Selección Modelos	Predicción de enfermedades.	Genómica con Big Data.	Optimización de accuracy en datasets masivos.

Fuente: Adaptado de Kaggle y Real-world ML cases.

Conclusiones de la Unidad 4

Interpretar y seleccionar modelos asegura valor actionable de Big Data. LDA ofrece base sólida; herramientas como R facilitan análisis. Futuro: XAI (Explainable AI) para transparencia en modelos complejos.

Bibliografía

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning. Springer.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning with Applications in R. Springer.
- Kuhn, M. (2008). Building Predictive Models in R Using the caret Package. Journal of Statistical Software.
- Additional: RDocumentation - lda.
<https://www.rdocumentation.org/packages/MASS/versions/7.3-58.1/topics/lda>
- Analytics Vidhya. (2020). Linear Discriminant Analysis · A Complete Guide.
<https://www.analyticsvidhya.com/blog/2020/10/linear-discriminant-analysis-a-complete-guide/>
- DataCamp. (2023). Model Interpretation in R.
<https://www.datacamp.com/tutorial/model-interpretation-r>
- SHAP Documentation. <https://shap.readthedocs.io/en/latest/>