

Material de Lectura Extendido

Unidad 4: Interpretación de resultados y modelos estadísticos

Departamento de Educación a Distancia

Analítica de Big Data

Material de Lectura - Unidad 4: Interpretación de Resultados y Modelos Estadísticos en Big Data

Año 2025

Unidad 4: Interpretación de Resultados y Modelos Estadísticos en Big Data

La interpretación de resultados es crucial para convertir datos en acciones. Esta unidad cubre análisis discriminante lineal (LDA), interpretación de modelos, selección de resultados y generación de información estadística en Big Data. Incluimos teoría, ventajas, ejemplos en R, tablas comparativas, diagramas y casos reales para un entendimiento profundo.

4.1 Introducción a la Interpretación en Modelos Estadísticos

En Big Data, interpretar modelos implica entender coeficientes, importancia de variables y métricas de performance. Evita 'caja negra' con técnicas explicables; clave para toma de decisiones éticas y accionables.

Tabla 1: Métricas Clave para Interpretación de Modelos

Métrica | Descripción | Uso | Ejemplo en R

Accuracy | Proporción de predicciones correctas. | Clasificación general. | `confusionMatrix()`
`accuracy`.

Precision/Recall | Balance falsos positivos/negativos. | Clasificación imbalanceada. | `precision()` /
`recall()` en `caret`.

AUC-ROC | Área bajo curva ROC. | Discriminación clases. | `roc()` en `pROC`.

R-squared | Varianza explicada. | Regresión. | `summary(lm_model)$r.squared`.

Feature Importance | Contribución de variables. | Selección modelos. | `varImp()` en `caret`.

Fuente: Adaptado de RDocumentation y Caret package docs.

Error al insertar figura: 404 Client Error: Not Found for url:

https://miro.medium.com/v2/1*9j9ZqNcQzW3GwFQ8b1Wv3Q.png

4.2 Análisis Discriminante Lineal (LDA)

LDA es un método supervisado para clasificación y reducción dimensional. Maximiza separación entre clases minimizando varianza intra-clase. Asume normalidad multivariada y covarianza igual; útil en reconocimiento de patrones.

Función Discriminante:
$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k$$

Tabla 2: Ventajas y Desventajas de LDA

Aspecto | Ventajas | Desventajas

Eficiencia | Rápido y computacionalmente ligero. | Asume normalidad y homocedasticidad.

Reducción Dimensional | Proyecta datos en espacio de baja dimensión. | Sensible a outliers.

Interpretabilidad | Coeficientes indican importancia de features. | No maneja no-linealidades.

Escalabilidad | Buena para datasets medianos en Big Data. | Requiere matrices invertibles (no colinealidad).

Fuente: Adaptado de Analytics Vidhya LDA Tutorial.

Ejemplo en R: LDA con MASS

R Code:

```
library(MASS)library(caret)# Datos irisdata(iris)# Train/test splitset.seed(123)trainIndex <-  
createDataPartition(iris$Species, p=0.8, list=FALSE)train <- iris[trainIndex,]test <-  
iris[-trainIndex,]# Entrenar LDAmodel <- lda(Species ~ ., data=train)# Predecirpredicciones <-  
predict(model, test[,1:4])$class# EvaluaciónconfusionMatrix(predictions, test$Species)# Visualizar  
proyeccionesplot(model)
```

Este código entrena LDA en iris, predice y visualiza separaciones.

Error al insertar figura: 406 Client Error: Not Acceptable for url:

https://sebastianraschka.com/images/blog/2014/linear-discriminant-analysis/iris_lda_1.png

4.3 Interpretación y Selección de Resultados

Interpretar implica analizar métricas, visualizaciones y feature importance. Selección: elegir modelo por cross-validation, AIC/BIC o ensemble.

Ejemplo en R: Interpretación con varImp y ROC

R Code:

```
library(caret)library(pROC)# Asumir modelo entrenado (ej. randomForest)model <- train(Species ~ .,  
data=iris, method="rf")# Importancia de variablesvarImp(model)# ROC para multiclass  
(one-vs-all)multi_roc <- multiclass.roc(test$Species, as.numeric(predictions))print(multi_roc$auc)#  
Plot ROCplot(multi_roc)
```

Usa varImp para importancia y pROC para curvas ROC en interpretación.

Tabla 3: Criterios para Selección de Modelos

Criterio | Descripción | Fórmula/Ejemplo

Cross-Validation | Evalúa performance en folds. | k-fold CV error.

AIC/BIC | Balancea fit y complejidad. | $AIC = 2k - 2\ln(L)$.

Ensemble Voting | Combina múltiples modelos. | Majority vote.

SHAP Values | Explicabilidad local/global. | SHAP library in R.

Fuente: Adaptado de Hastie et al. (2009) Elements of Statistical Learning.

Error al insertar figura: 404 Client Error: Not Found for url:

<https://christophm.github.io/interpretable-ml-book/images/shap-header.png>

4.4 Generación de Información Estadística en Big Data

Generar info implica reportes, dashboards y narrativas. En R, usa Shiny para interactivos o rmarkdown para informes reproducibles.

Ejemplo en R: Generar Reporte con rmarkdown

R Markdown Code:

```
# En un archivo .Rmd---title: "Reporte Big Data"output: html_document---``r setup,  
include=FALSEknitr::opts_chunk$set(echo = TRUE)``## Resumen Modelomodel <- lda(Species ~ .,  
data=iris)summary(model)## Visualizaciónplot(model)``# Renderizar: rmarkdown::render('report.Rmd')  
Crea reportes reproducibles integrando código, resultados y narrativas.
```

4.5 Comparación y Selección de Modelos en Big Data

Compara por métricas, complejidad y escalabilidad. En Big Data, prioriza paralelizables como LDA sobre computacionalmente intensivos.

Tabla 4: Comparación de Modelos para Clasificación

Modelo | Asunciones | Fortalezas | Debilidades | Escalabilidad en Big Data

LDA | Normalidad, covarianza igual. | Reducción dimensional, interpretable. | Sensible a violaciones. | Buena con paralelización.

QDA | Normalidad, covarianza diferente. | Más flexible que LDA. | Sobrefit en alta dimensión. |

Moderada.

Logistic Regression | Linealidad en logit. | Probabilidades, regularización. | No captura no-linealidades. | Alta con Spark ML.

SVM | Margen máximo. | Efectivo en alta dimensión. | Lento en entrenamiento. | Buena con kernels aproximados.

Fuente: Adaptado de Elements of Statistical Learning.

4.6 Aplicaciones Reales en Big Data

LDA en reconocimiento facial (Eigenfaces), interpretación en finanzas para riesgo, selección en bioinformática para genes.

Tabla 5: Aplicaciones Reales de Modelos en Big Data

Modelo	Aplicación	Ejemplo	Beneficio
--------	------------	---------	-----------

LDA	Clasificación de documentos.	Topic modeling en noticias.	Reducción dimensional para escalabilidad.
-----	------------------------------	-----------------------------	---

Interpretación	Análisis de sentiment.	Twitter data insights.	Explicabilidad para decisiones de marketing.
----------------	------------------------	------------------------	--

Selección Modelos	Predicción de enfermedades.	Genómica con Big Data.	Optimización de accuracy en datasets masivos.
-------------------	-----------------------------	------------------------	---

Fuente: Adaptado de Kaggle y Real-world ML cases.

Conclusiones de la Unidad 4

Interpretar y seleccionar modelos asegura valor actionable de Big Data. LDA ofrece base sólida; herramientas como R facilitan análisis. Futuro: XAI (Explainable AI) para transparencia en modelos complejos.

Bibliografía

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning. Springer.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning with Applications in R. Springer.
- Kuhn, M. (2008). Building Predictive Models in R Using the caret Package. Journal of Statistical Software.
- Additional: RDocumentation - lda.
<https://www.rdocumentation.org/packages/MASS/versions/7.3-58.1/topics/lda>
- Analytics Vidhya. (2020). Linear Discriminant Analysis - A Complete Guide.
<https://www.analyticsvidhya.com/blog/2020/10/linear-discriminant-analysis-a-complete-guide/>
- DataCamp. (2023). Model Interpretation in R.
<https://www.datacamp.com/tutorial/model-interpretation-r>
- SHAP Documentation. <https://shap.readthedocs.io/en/latest/>